

AIM 的初始化机制

差分隐私合成数据中的智能初始化、预算推导与数值型属性处理

基于 AIM 论文、Private-PGM 文献与官方实现整理




图 1 AIM 初始化在 select-measure-generate 框架中的位置

核心结论 AIM 不从完全均匀的联合分布开始。它先用少量隐私预算测量 workload 向下闭包中涉及属性的一维边缘分布，再通过 Private-PGM 拟合一个图结构上独立的初始模型。数值型属性必须在进入 AIM 之前裁剪并离散化；AIM 初始化的是分箱计数，而不是连续密度。

整理日期：2026 年 7 月 24 日

内容概览

1. 背景：AIM 为什么需要专门的初始化
 2. 记号、输入与初始化候选集合
 3. 初始化算法的逐步过程
 4. 高斯噪声与隐私预算推导
 5. Private-PGM 如何形成独立初始模型
 6. 这种初始化为什么优于均匀初始化
 7. 数值型属性的初始化：裁剪、分箱与还原
 8. 一个完整示例
 9. 官方实现的代码映射
 10. 常见误解、边界条件与实现检查表
- 附录：简化伪代码与参考文献

阅读提示 本文聚焦“初始化”而非 AIM 的全部迭代机制。后续指数机制选择、噪声退火、模型容量控制和不确定性量化只在与初始化衔接相关时简要提及。

1. 背景：AIM 为什么需要专门的初始化

AIM (Adaptive and Iterative Mechanism) 属于基于边缘分布的差分隐私合成数据方法。其总体范式是：先选择需要发布的低维边缘查询，再对这些查询进行差分隐私测量，最后使用 Private-PGM 将多个带噪边缘整合为一个一致的高维概率模型，并从中采样合成记录。[1][4]

AIM 的直接前身之一是 MWEM+PGM。若从联合域上的均匀分布开始，初始模型不仅不了解属性之间的相关性，甚至连每个单独属性的基本分布也不正确。这样一来，前几轮自适应选择往往只是反复挑选覆盖不同属性的一维或近似一维信息，以修正最基础的单变量分布。每一次“私有选择”本身也会消耗隐私预算。

AIM 的“智能初始化”把这部分工作提前并固定化：一维边缘集合可以由 schema 与 workload 决定，不需要查看私有计数，因此可以直接测量所有相关的一维边缘；这样只为高斯测量付费，而不再为逐个选择它们支付指数机制的预算。[1]

设计直觉 先学习“便宜、稳定、几乎肯定需要”的单变量统计量，再把昂贵的自适应选择预算留给属性间相关性。

2. 记号、输入与初始化候选集合

2.1 数据域与边缘查询

设数据集 D 包含 N 条记录，每条记录由 d 个属性组成： $x=(x_1,\dots,x_d)$ 。AIM 论文假设每个属性 x_j 的取值域 Ω_j 是有限集合，因此完整域 $\Omega=\Omega_1\times\cdots\times\Omega_d$ 也是离散域。[1]

对于属性子集 $r\subseteq\{1,\dots,d\}$ ，边缘查询 $M_r(D)$ 是在 Ω_r 上的计数直方图。若 r 只含一个属性，它是一维边缘；若 r 含两个属性，它是二维列联表。AIM 的测量单位不是单个 cell，而是完整边缘向量。

2.2 workload 与 downward closure

workload W 是希望合成数据重点保持准确的一组加权边缘查询。AIM 首先构造 workload 的向下闭包：

$$W^+ = \{ r : \text{存在 } s \in W, \text{ 使得 } r \subseteq s \}$$

初始化集合不是无条件包含数据表的全部属性，而是：

$$R_1 = \{ r \in W^+ : |r|=1 \}$$

因此，只有被 workload 中至少一个查询覆盖的属性才会进入标准初始化。如果 workload 覆盖全部 d 个属性，则 $|R_1|=d$ ；如果某个属性从未出现在 workload 中，它通常不会被 AIM 的候选集合测量，其初始状态也不会由私有数据校正。

符号	含义
d	数据属性数量
W	加权边缘 workload
W^+	workload 的向下闭包
R_1	W^+ 中的一维边缘集合
$m= R_1 $	初始化实际涉及的一维边缘数量
ρ	总 zCDP 隐私预算
T	默认迭代轮数基准， $T=16d$
α	测量预算比例参数，默认 $\alpha=0.9$
σ_0	初始化及初始轮次的高斯噪声标准差

表 1 初始化相关的主要记号

3. 初始化算法的逐步过程

3.1 步骤 1：确定固定的一维测量集合

AIM 先从 W^+ 中提取 R_1 。这个集合只依赖公开的 workload 与数据域定义，不依赖每个箱中的私有人数。因此，“决定要测量哪些一维边缘”本身不需要使用指数机制，也不会额外泄露数据内容。

3.2 步骤 2：为每个一维边缘生成完整计数向量

对每个 $r \in R_1$ ，计算真实一维边缘 $M_r(D)$ 。若属性 r 有 n_r 个离散状态，则 $M_r(D)$ 是长度为 n_r 的向量；每条记录恰好给其中一个 cell 增加 1。

在论文采用的 add/remove 邻接关系下，完整直方图的 L_2 灵敏度为 1：增加或删除一条记录只会让一个 cell 改变 1。因此对整个向量使用标准差为 σ_0 的独立高斯噪声即可。

3.3 步骤 3：加入独立高斯噪声

$$\tilde{y}_r = M_r(D) + \mathcal{N}(0, \sigma_0^2 I)$$

这里 I 是与直方图长度匹配的单位矩阵，表示各个 cell 使用相同噪声尺度并独立扰动。原始带噪向量可能出现负数、总和偏离 N 等现象；AIM 不直接把这些数当作最终发布结果，而是交给 Private-PGM 做一致性估计。

3.4 步骤 4：累积 measurements

每个测量通常记录三类信息：被测量的 clique/属性集合 r 、带噪向量 $\tilde{y}_r$ 、以及该向量的噪声标准差 σ_0 。后续 Private-PGM 会联合使用全部 measurements，而不是分别独立修正每个直方图。

3.5 步骤 5：使用 Private-PGM 拟合初始分布

Private-PGM 通过图模型参数化和基于噪声尺度加权的优化，将多个可能不一致的带噪边缘投影到某个合法的全局离散分布上。官方实现使用 `MirrorDescent().estimate(...)` 执行这一估计。[2][3][4]

这一拟合以及随后从模型中采样都属于差分隐私的后处理：它们只访问已经加入噪声的 measurements，因此不再消耗新的隐私预算。

$$\hat{p}_0(x_1, \dots, x_d) \propto \prod_{j \in R_1} \psi_j(x_j)$$

图 2 只测量一维 clique 时，初始图模型仅含单变量势函数

初始化输出 初始化并不直接输出合成数据，而是输出初始概率模型 $\hat{p}_0$ 、测量列表和已消耗预算 ρ_{used} 。随后 AIM 才开始自适应选择二维或更高维边缘。

4. 高斯噪声与隐私预算推导

4.1 默认超参数

AIM 论文和官方实现使用默认值 $T=16d$ 、 $\alpha=0.9$ ，并将初始高斯噪声设置为：

$$T = 16d, \quad \alpha = 0.9, \quad \sigma_0 = \sqrt{\frac{T}{2\alpha\rho}}$$

式 1 默认初始化噪声尺度

T 是一个与属性数成正比的轮数基准； α 控制每轮预算中用于高斯测量的部分。默认 $\alpha=0.9$ 意味着测量预算占主导，而剩余部分用于私有选择。初始化集合是固定的，不需要选择预算，但沿用了相同的初始测量噪声尺度。

4.2 单个一维边缘的 zCDP 成本

在 L_2 灵敏度为 1 的高斯机制下，标准差为 σ 的一次向量测量满足 $1/(2\sigma^2)$ -zCDP。因此初始化中每个一维边缘的成本为 $\alpha\rho/T$ 。若一共测量 $m=|R_1|$ 个一维边缘，总初始化成本是 $m\alpha\rho/T$ 。

$$\rho_{\text{one}} = \frac{1}{2\sigma_0^2} = \frac{\alpha\rho}{T}$$

$$\rho_{\text{init}} = m \frac{\alpha\rho}{T}; \quad m = d \Rightarrow \rho_{\text{init}} = \frac{0.9}{16}\rho = 0.05625\rho$$

式 2 初始化预算的通用表达式与默认上限

4.3 为什么默认比例约为 5.625%

当 workload 覆盖全部 d 个属性时， $m=d$ 。代入 $T=16d$ 和 $\alpha=0.9$ ，可得初始化消耗 0.05625ρ ，即总 zCDP 预算的 5.625%。该比例与 d 无关； d 增大时，单次测量噪声 σ_0 会随 $\sqrt{d}$ 增长，从而抵消测量数量的线性增加。

默认配置、且 workload 覆盖全部 d 个属性时的 ρ -zCDP 预算比例图 3 默认且 $m=d$ 时的初始化预算比例

若 workload 只覆盖部分属性，则 $m < d$ ，初始化比例进一步下降： $\rho_{\text{init}}/\rho = 0.9m/(16d)$ 。因此“5.625%”是标准覆盖场景下的默认值，不是所有运行都严格相同。

参数	示例值	解释
d	20	总属性数
m	18	workload 实际覆盖 18 个属性
T	320	$16d$
ρ	1.0	用于说明比例的 zCDP 总预算

参数	示例值	解释
σ_0	约 13.33	$\sqrt{(320/1.8)}$
ρ_{init}	0.050625	$18 \times 0.9/320$ ，即总预算的 5.0625%

表 2 一个不覆盖全部属性的预算示例

4.4 邻接关系的注意事项

上述灵敏度与预算公式采用 add/remove 一条记录的无界邻接定义；论文背景和官方 Mechanism 类也按 bounded=False 运行。[1][2] 若系统采用“替换一条记录”的有界邻接，完整直方图的 L_2 灵敏度通常为 $\sqrt{2}$ ，需要相应调整噪声或预算记账，不能直接照搬该公式。

5. Private-PGM 如何形成独立初始模型

5.1 “独立”指的是图结构，而不是均匀分布

只测量一维边缘时，Private-PGM 的 clique 集合只包含单属性 clique，图中不存在连接两个属性的边。因此模型结构假设属性之间独立，但每个属性自身的概率分布由带噪一维边缘估计，而不是均匀分布。

例如年龄箱可能明显偏向 25-44 岁，教育程度可能集中在本科和高中；初始化会保留这些单变量形状，但暂时假设“年龄与教育程度独立”。

5.2 一致性投影的作用

- 将可能为负的带噪 cell 调整为合法的非负概率或计数估计；
- 处理测量总和偏离记录数等约束；
- 用统一的全局分布解释多个 measurements；
- 为未测量的高阶边缘提供最大熵/图模型意义下的估计。

需要注意：Private-PGM 的输出不是简单地把所有负数截为 0 后各自归一化。它进行联合优化，因此会利用噪声尺度和全局一致性约束。

5.3 初始化模型如何支持后续选择

后续 AIM 会比较真实候选边缘 $M_r(D)$ 与当前模型边缘 $M_r(\hat{p})$ 的 L_1 差异，并扣除预计的高斯噪声误差，再乘以与 workload 相关的权重。因为 $\hat{p}_0$ 已经解释了一维分布，剩余误差更能反映真正的属性交互，而不是某个单变量分布尚未学习。

6. 这种初始化为什么优于均匀初始化

维度	均匀初始化	AIM 智能初始化
隐私开销	初始化本身为 0，但前几轮选择与测量常用于纠正一维分布	一次性测量一维边缘，消耗少量测量预算
初始单变量分布	通常明显错误	由带噪一维边缘校正

维度	均匀初始化	AIM 智能初始化
属性相关性	默认独立且单变量也均匀	默认独立，但单变量形状已学习
后续选择重点	容易优先发现“哪个属性分布最不均匀”	更容易聚焦二维及高阶相关性
选择预算利用	为选择基础一维信息付费	一维集合数据无关，无需私有选择

表 3 均匀初始化与 AIM 智能初始化的对比

论文对这一设计的解释是：MWEM+PGM 在早期往往选择覆盖互不相同属性集合的边缘，目的是修复一维分布。AIM 直接测量全部相关一维边缘，避免把指数机制预算花在这类几乎必然要选的查询上。[1]

不是“免费提高精度” 智能初始化仍然会消耗高斯测量预算。它的优势来自预算用途的重新配置：用少量固定测量替代多轮私有选择，并为后续相关性学习提供更好的起点。

7. 数值型属性的初始化：裁剪、分箱与还原

7.1 原始 AIM 不直接处理连续变量

AIM 与 MBI/Private-PGM 的基本对象是有限离散域上的边缘直方图。论文明确指出：数值型属性必须在运行 AIM 前进行适当离散化；离散化质量会显著影响合成数据质量。[1][3]

数值型属性不在 AIM 内部连续建模：必须先离散化




图 4 数值型属性进入 AIM 初始化前后的处理链路

7.2 推荐的预处理步骤

1. 确定公开或经 DP 处理的有效范围 $[L, U]$ ，将异常值裁剪到该范围；
2. 定义分箱边界 $e_0 < e_1 < \dots < e_K$ ，可采用业务区间、等宽分箱或基于公开数据的分位区间；
3. 把每个原始数值 x 编码为箱编号 $B(x)$ ；
4. 把缺失值视为单独离散状态，避免与真实数值箱混淆；
5. 将箱编号写入 AIM 的 Domain，并像普通类别属性一样测量一维边缘。

$$B(x) = k, \quad e_k \leq x < e_{k+1}$$

$$\tilde{c}_k = c_k + Z_k, \quad Z_k \sim N(0, \sigma_0^2)$$

式 3 数值分箱与初始化噪声测量

假设收入被分为 $K=5$ 个区间。AIM 初始化得到的是五个箱的带噪声人数和相应概率，而不是均值、方差、核密度或高斯混合模型参数。后续 AIM 学习的相关性也发生在“收入箱”与其他离散属性之间。

7.3 分箱数对隐私和效用的不同影响

一个容易混淆的事实是：在 add/remove 邻接下，无论一维直方图有 5 个箱还是 50 个箱，完整向量的 L_2 灵敏度仍为 1，因此单次一维边缘测量的 zCDP 成本并不直接随 K 增长。

但效用和计算会明显恶化：箱越多，每箱真实人数越少，相对噪声越大；与其他属性形成联合边缘时，cell 数按域大小相乘；Private-PGM 的图模型推断也更容易遇到内存与运行时间瓶颈。论文实验中的属性域经过预处理，多数属性的域大小不超过约 50；官方代码也假定不存在大基数类别属性。[1][2]

分箱策略	优点	风险/适用场景
业务固定区间	边界公开、解释性强、隐私审计简单	若数据分布极不均匀，部分箱可能过稀
等宽分箱	实现简单、保留绝对尺度	长尾分布下可能浪费大量空箱
公开数据分位分箱	各箱信号通常较平衡	要求公开参考分布与私有数据足够接近
私有数据分位分箱	可适应真实分布	边界学习本身必须使用额外 DP 预算
每个整数一个状态	无分箱偏差	高基数、稀疏、联合域爆炸，通常不推荐

表 4 数值型属性常见分箱策略

7.4 分箱边界本身也可能泄露隐私

如果直接使用私有数据的精确最小值、最大值、分位点或聚类结果确定边界，却没有对这些步骤进行 DP 处理，那么“离散化 + AIM”的完整流水线不能自动继承 AIM 的原始隐私保证。稳妥做法是使用公开 schema/法规区间/外部公开数据，或者为边界学习单独分配并记录隐私预算。

7.5 合成后如何恢复数值

- 箱中点：确定且容易解释，但会产生大量重复数值；
- 箱内均匀采样：可生成连续外观，但“均匀”是额外假设，不是 AIM 学到的；
- 依据公开参考分布在箱内采样：能改善形状，但质量依赖外部数据；
- 保留箱编号：最忠实于 AIM 实际保证，适合后续按区间统计。

只要还原过程仅使用 DP 模型输出、公开边界和额外随机数，它就是后处理，不增加隐私损失。不能回到私有原始记录中按箱抽取真实值，否则会破坏端到端隐私。

7.6 顺序与距离信息的限制

AIM 把箱编号视为普通离散状态，不会自动知道“箱 3 比箱 8 更接近箱 2”。相邻区间的顺序关系主要靠预处理和下游聚合体现。范围查询可以通过相邻箱计数求和得到，但模型的查询选择与图结构没有显式利用连续距离。

8. 一个完整示例

考虑四个属性：年龄箱 A、教育程度 B、收入箱 C、地区 D。workload 为 $W=\{(A,B,C),(B,C,D)\}$ ，所有查询权重均为 1。

其向下闭包包括所有非空子集，例如 (A)、(B)、(C)、(D)、(A,B)、(B,C)、(C,D) 以及原三维边缘。因此初始化集合 $R_1=\{(A),(B),(C),(D)\}$ 。

步骤	操作	结果
1	计算 A、B、C、D 四个一维直方图	获得各年龄箱、教育类别、收入箱和地区的人数
2	对四个完整向量加入 σ_0 高斯噪声	形成四个 DP measurements
3	Private-PGM 联合拟合	得到 $\hat{p}_0(A,B,C,D) \approx \hat{p}(A)\hat{p}(B)\hat{p}(C)\hat{p}(D)$
4	进入自适应迭代	优先寻找当前模型不能解释的 B-C、A-B-C 等交互
5	最终采样	生成包含 A、B、C、D 的离散合成记录

表 5 四属性 workload 的初始化过程

假设收入 C 原先是连续金额，并预先定义 [0,30k)、[30k,50k)、[50k,80k)、[80k,120k)、[120k,+) 五个区间。AIM 只看到 0-4 的箱编号。初始化后，它能较好保持每个收入区间的总体占比，但尚不知道高学历是否更集中在高收入箱；这种关联需要后续选择 (B,C) 或包含它的高阶边缘来学习。

9. 官方实现的代码映射

官方 mbi 仓库中的 mechanisms/aim.py 与论文算法基本对应。下面是为了阅读而简化的核心片段；变量名保持实现风格。[2]

```

rounds = self.rounds or 16 * len(data.domain)
candidates = compile_workload(workload)

initial_cliques = [cl for cl in candidates if len(cl) == 1]
sigma = np.sqrt(rounds / (2 * 0.9 * self.rho))

measurements = []
rho_used = len(initial_cliques) * 0.5 / sigma**2

for cl in initial_cliques:
    x = data.project(cl).datavector()
    y = x + self.gaussian_noise(sigma, x.size)
    measurements.append(LinearMeasurement(y, cl, stddev=sigma))

model = estimation.MirrorDescent().estimate(
    data.domain, measurements, iters=self.max_iters
)

```

论文概念	代码位置/表达	说明
T=16d	rounds = ... 16 * len(data.domain)	默认轮数基准
R_1	len(cl) == 1	从编译后的 downward-closure 候选中

论文概念	代码位置/表达	说明
		取一维 clique
σ_0	<code>np.sqrt(rounds/(2*0.9*self.rho))</code>	初始化高斯噪声尺度
$M_r(D)$	<code>data.project(cl).datavector()</code>	完整边缘计数向量
高斯测量	<code>x + gaussian_noise(...)</code>	逐 cell 独立同方差噪声
measurement 元数据	<code>LinearMeasurement(..., stddev=sigma)</code>	记录 clique、带噪向量与噪声尺度
Private-PGM 拟合	<code>MirrorDescent().estimate(...)</code>	形成初始图模型

表 6 论文初始化步骤与官方代码的对应关系

代码接口接收 (ϵ, δ) ，基类通过 `cdp_rho(epsilon, delta)` 转换为内部 `self.rho`，再由 AIM 使用 zCDP 进行组合记账。[2]

实现提供 `initial_cliques` 参数作为扩展入口。标准配置下它等于全部一维候选。若自行传入不同集合，尤其是子集或高阶 clique，应重新核对实际测量数量、灵敏度与 `rho_used` 是否一致；论文默认结论只针对标准的一维初始化。

10. 常见误解、边界条件与实现检查表

10.1 常见误解

误解	正确理解
AIM 从均匀分布开始	AIM 先测量相关一维边缘，初始模型单变量分布不是均匀的
它测量表中所有属性	它测量 workload 向下闭包中出现的一维属性；未覆盖属性不一定测量
一维边缘每个 cell 分别计费	一个完整一维直方图作为一次向量查询计费
初始化学到了相关性	初始图结构是独立模型，相关性由后续高阶边缘加入
数值列会拟合连续分布	必须先离散化，AIM 学的是箱概率
分箱越细隐私成本越高	单个向量测量的灵敏度不一定增大，但信噪比和计算成本会恶化
Private-PGM 拟合会追加隐私损失	拟合和采样是 DP measurements 的后处理

表 7 关于 AIM 初始化的常见误解

10.2 什么时候初始化可能表现不佳

- 数据量很小或一维域很大，导致每个 cell 的真实计数与 σ_0 相比过低；
- workload 很小，直接测量全部目标查询的 Gaussian+PGM 可能比 AIM 更合适；
- 数值分箱不合理，重要变化被过粗合并，或过细导致大量稀疏箱；
- 存在大基数标识符、邮编、详细职业代码等属性，未经压缩就进入 PGM；
- workload 漏掉了下游实际关心的属性，导致这些属性没有可靠初始化。

10.3 工程实施检查表

- ☐ 明确邻接关系是 add/remove 还是 replace-one;
- ☐ 所有属性域和数值裁剪范围都已公开定义或经过 DP 处理;
- ☐ workload 覆盖了需要在合成数据中保持的属性;
- ☐ 记录 $m=|R_1|$, 使用 $m\alpha/T$ 计算实际初始化预算;
- ☐ 检查每个一维域的大小和预期每箱计数;
- ☐ 将缺失值、结构性零和非法组合纳入域设计;
- ☐ 使用 Private-PGM 统一拟合, 而非简单截断负数后独立归一化;
- ☐ 合成后的数值还原只依赖 DP 输出和公开信息;
- ☐ 保存随机种子、预算参数、分箱边界和 workload 版本, 便于复现和审计。

一句话总结 AIM 的初始化是“用少量预算发布 workload 相关的一维带噪直方图, 并将其投影为独立 Private-PGM”, 而不是“将联合分布设为均匀”或“对连续变量拟合参数分布”。

附录 A：初始化的简化伪代码

输入：离散数据集 D , workload W , 总预算 p , 属性数 d

```

1.  $W_{plus} \leftarrow \text{downward\_closure}(W)$ 
2.  $R1 \leftarrow \{r \in W_{plus} : |r| = 1\}$ 
3.  $T \leftarrow 16d, \alpha \leftarrow 0.9$ 
4.  $\sigma_0 \leftarrow \sqrt{T / (2\alpha p)}$ 
5.  $\text{measurements} \leftarrow []$ 
6. 对每个  $r \in R1$ :
     $y_r \leftarrow M_r(D) + \text{Normal}(0, \sigma_0^2 I)$ 
     $\text{measurements.append}(r, y_r, \sigma_0)$ 
7.  $p_{\text{hat}0} \leftarrow \text{PrivatePGM.fit}(\text{measurements})$ 
8.  $\rho_{\text{used}} \leftarrow |R1| / (2\sigma_0^2)$ 
9. 返回  $p_{\text{hat}0}$ ,  $\text{measurements}$ ,  $\rho_{\text{used}}$ 

```

伪代码省略了 AIM 后续的候选容量过滤、指数机制选择、噪声退火和重复模型拟合。第 7 步完全属于后处理。

参考文献与来源

- [1] McKenna, R.; Mullins, B.; Sheldon, D.; Miklau, G. “AIM: An Adaptive and Iterative Mechanism for Differentially Private Synthetic Data.” *Proceedings of the VLDB Endowment*, 15(11):2599-2612, 2022. DOI: 10.14778/3551793.3551817.
- [2] Ryan McKenna 等, mbi / mechanisms / aim.py 官方开源实现；以及 mechanisms / mechanism.py 中的 (ϵ, δ) 到 p 的转换与噪声工具。访问日期：2026-07-24。
- [3] mbi documentation, Introduction：该库用于从带噪边缘观测估计离散分布，并生成一致的图模型与合成数据。访问日期：2026-07-24。
- [4] McKenna, R.; Sheldon, D.; Miklau, G. “Graphical-model based estimation and inference for differential privacy.” *ICML 2019*, PMLR 97:4435-4444.

在线来源：[AIM 论文 \(PVLDB\)](#)；[AIM 官方实现 \(GitHub\)](#)；[MBI 文档](#)。

说明 本文对预算比例、workload 覆盖条件和数值属性流水线进行了推导与工程化解释。涉及自定义 initial_cliques、不同邻接关系或私有分箱机制时，应重新完成端到端隐私会计。