

AIM 最终合成数据评价方法详解

从 workload error 到后验置信误差界

核心结论

AIM 的最终效用评价以目标 workload 上的平均归一化 L1 边缘误差为核心。实际工程中还应同时报告模型误差、合成样本误差、误差分布和后验高概率上界，避免只看一个平均数。

技术总结文档

基于 McKenna 等人的 AIM 论文及官方 MBI 实现

2026 年 7 月

目录

1. 评价问题的边界：AIM 究竟保存什么
 2. 核心指标：workload error
 3. 逐步计算示例与数值解释
 4. L1 距离与总变差距离的换算
 5. 模型误差与合成样本误差
 6. 后验误差量化：发布后如何给出可信上界
 7. 推荐的完整评价体系
 8. 常见误区与报告模板
- 附录：符号表、计算伪代码与参考文献

阅读提示

第 2-5 节回答“有原始数据时如何计算真实误差”；第 6 节回答“合成数据发布后，不能再次访问原始数据时，如何利用 AIM 已发布的私有中间结果给出误差上界”。

1. 评价问题的边界：AIM 究竟保存什么


AIM 是一个 workload-aware 的差分隐私合成数据方法。它并不承诺在所有可能的统计任务上都精确，而是针对用户事先给定的一组加权边缘查询 workload 进行优化。因此，“合成结果好不好”首先必须相对于某个目标 workload 来定义。

评价层次	所回答的问题	典型量
算法内部选择	下一轮测量哪个边缘最划算？	质量分数 q_r ；不是最终准确率
模型层评价	Private-PGM 学到的分布是否准确？	真实边缘 vs 模型边缘
数据层评价	导出的有限行合成表是否准确？	真实边缘 vs 合成样本边缘
发布后评价	不再访问原始数据时能否说明误差？	后验高概率误差上界

最重要的区分

AIM 每轮使用的 quality score 只服务于“选什么查询”，最终论文实验的主效用指标则是 workload error。二者不能混为同一个准确率。

边缘查询 $M_r(D)$ 可以理解为：选取属性集合 r 后，对所有可能的联合取值进行计数，得到一个多维列联表展开后的计数向量。例如 $r=(\text{年龄组}, \text{教育程度})$ ，则 $M_r(D)$ 是年龄组与教育程度的二维交叉计数。



2. 核心指标：workload error

设目标 workload 中共有 k 个边缘查询 $r_1, \dots, r_k$ ，对应非负权重 $c_1, \dots, c_k$ 。真实数据为 D ，合成数据为 $\hat{D}$ 。AIM 论文把最终合成数据的误差定义为：

$$\text{Error}(D, \hat{D}) = \frac{1}{k|D|} \sum_{i=1}^k c_i \|M_{r_i}(D) - M_{r_i}(\hat{D})\|_1$$

符号	含义
k	workload 中的边缘查询数量
$ D $	真实数据的记录数

符号	含义
c_i	第 i 个目标边缘的业务或评价权重
$M_{\{r_i\}}(D)$	真实数据在 r_i 上的计数直方图
$M_{\{r_i\}}(\hat{D})$	合成数据在 r_i 上的计数直方图
$\ \cdot\ _1$	所有直方图单元绝对误差之和

该公式先对每个目标边缘计算计数向量的 L1 距离，再乘以其权重，最后除以 workload 大小 k 和真实数据规模 $|D|$ 。除以 $|D|$ 的作用是把“错了多少条计数”转换成可跨数据规模比较的归一化误差。

当真实数据和合成数据的行数相同，把每个边缘直方图除以行数即可得到概率分布 $p_{\{r_i\}}$ 和 $p_{\hat{\{r_i\}}}$ ，此时公式等价为：

$$\text{Error}(D, \hat{D}) = \frac{1}{k} \sum_{i=1}^k c_i \|p_{r_i} - \hat{p}_{r_i}\|_1 \quad (|D| = |\hat{D}|)$$

如何解释数值

误差越小越好，0 表示目标 workload 上完全一致。对单位权重的单个边缘，概率分布 L1 距离位于 $[0,2]$ ；多个加权边缘的总体范围会受权重定义影响，因此报告时必须写清权重和聚合方式。

2.1 权重 c_i 的作用

权重允许评价指标向关键任务倾斜。例如医疗数据中可以提高“年龄×诊断”的权重，劳动力数据中可以提高“教育×收入”的权重。需要注意的是：改变权重不只是改变报告方式；如果同一 workload 同时作为 AIM 的输入，它还会影响算法把隐私预算和模型容量放在哪里。

- 单位权重：所有 $c_i=1$ ，适合通用比较。
- 业务权重：关键边缘权重大，适合面向特定分析场景。
- 标准化权重：令权重和或均值固定，便于不同 workload 之间比较。


比较实验的必要条件

比较两个算法时，应使用同一预处理、同一 workload、同一权重、同一合成行数和同一误差归一化方式。否则数字可能不可比。

3. 逐步计算示例与数值解释

考虑一个三分类边缘，例如“教育程度”被分成 A、B、C 三类。真实与合成概率分布分别为：

类别	真实比例 p	合成比例 p_hat	绝对差
A	0.50	0.45	0.05
B	0.30	0.35	0.05
C	0.20	0.20	0.00
合计	1.00	1.00	0.10



这个边缘的 L1 误差为：

计算

$$|0.50-0.45| + |0.30-0.35| + |0.20-0.20| = 0.10$$

0.10 可以称为“10% 的归一化 L1 差异”，但不能解释成“10% 的个人记录生成错了”。它描述的是整个边缘概率质量需要重新分配多少的两倍，属于分布层面的差异。

若真实数据有 10,000 行、合成数据也有 10,000 行，对应计数向量可能是 (5000,3000,2000) 与 (4500,3500,2000)。计数 L1 距离是 1000，再除以 $|D|=10,000$ 后仍得到 0.10。

3.1 多个 workload 边缘如何汇总

假设 workload 有三个单位权重边缘，其归一化 L1 误差分别为 0.10、0.06 和 0.20，则总体 workload error 为：

平均误差

$$(0.10 + 0.06 + 0.20) / 3 = 0.12$$

只报告平均值可能掩盖个别非常差的边缘。因此建议同时报告中位数、90% 分位数、最大值，并列出差的最差若干边缘。

建议统计量	回答的问题
均值	整体平均表现如何？
中位数	典型边缘的表现如何？
90% / 95% 分位数	大多数边缘是否可靠？
最大误差	是否存在严重失败的边缘？
按边缘维度分组	一维、二维、三维边缘分别有多难？

4. L1 距离与总变差距离的换算

AIM 论文的 Definition 2 使用归一化 L1 距离；官方 MBI 命令行示例代码在输出时使用总变差距离（Total Variation, TV），两者只差一个固定系数：

$$TV(p, \hat{p}) = \frac{1}{2} \|p - \hat{p}\|_1 \quad \Longleftrightarrow \quad L_1 = 2 TV$$

在上一节的例子中，L1=0.10，而 TV=0.05。两者对算法排序完全一致，但数值会恰好相差一倍。

指标	公式	单个概率边缘范围	上一示例
L1 距离	$\ p - \hat{p}\ _1$	[0,2]	0.10
总变差距离	$0.5\ p - \hat{p}\ _1$	[0,1]	0.05

代码阅读注意

官方 aim.py 的示例评估包含 $0.5 * \text{norm}(\dots, 1)$ ，因此打印的是加权 TV 平均值，而不是论文公式中未乘 0.5 的 L1 数值。复现实验时必须明确采用哪一种口径。

4.1 为什么 L1/TV 适合边缘直方图

- 容易解释：直接累计各单元的概率或比例差异。
- 对正负偏差对称，不会因不同单元误差相互抵消。
- 适用于类别型和离散化后的数值型属性。
- 可以在不同维度边缘上使用统一计算方法。

但 L1/TV 不体现类别之间的距离。例如年龄相邻分箱之间的错位与跨越多个年龄箱的错位，在 L1 中可能有相同代价。因此对数值型属性还应补充 Wasserstein 距离、均值/分位数误差等指标。

5. 模型误差与合成样本误差

AIM 最终先得到一个 Private-PGM 概率模型 p_{hat} ，再从该模型导出有限行合成数据 D_{hat} 。因此可以计算两种误差：

误差类型	比较对象	主要反映
模型误差	$M_r(D)$ 与 $M_r(p_{\text{hat}})$	私有测量、查询选择和 PGM 拟合造成的偏差
合成样本误差	$M_r(D)$ 与 $M_r(D_{\text{hat}})$	模型误差，再加有限行导出或随机化舍入误差

$$\text{synthetic error} \approx \text{model error} + \text{finite sample error}$$

官方 MBI 代码同时计算 `model_errors` 和 `synth_errors`：前者把真实边缘与模型投影比较，后者把真实边缘与合成表投影比较。实际使用中，这两个值应一起报告。

诊断逻辑

若模型误差低而合成样本误差明显高，问题主要来自合成行数过少或导出波动；若两者都高，问题更可能来自隐私噪声、workload 覆盖、分箱、模型容量或推断误差。

5.1 合成行数的影响

从同一模型导出更多合成记录通常可以降低有限样本误差，但不会修复模型本身已经学错的分布。反过来，合成行数非常少时，即使模型边缘很准确，最终表中的稀有类别和高维组合也可能有较大波动。

- 公平比较时固定合成行数，通常设置为与真实数据相同。
- 对同一个模型重复导出多份合成表，可估计导出波动。
- 若使用 Private-PGM 的随机化舍入而非独立抽样，误差特性可能不同，但仍应通过重复运行检查稳定性。

5.2 机制随机性与重复实验

AIM 的高斯噪声、指数机制选择以及数据导出都有随机性。论文实验通常对同一配置重复运行，并报告平均值及波动范围。工程评估建议至少使用多个随机种子，并报告均值、标准差和最好/最差结果。

推荐报告项	示例
运行次数	5 或 10 个独立随机种子
中心位置	平均 workload error；中位数
不稳定性	标准差；最小值-最大值；四分位距

推荐报告项	示例
资源消耗	运行时间；峰值内存；最终 PGM 大小

6. 后验误差量化：发布后如何给出可信上界

在内部实验环境中，可以直接把合成数据与原始数据比较并计算真实 workload error。但公开发布后，直接公开任意新的精确误差可能再次访问敏感数据并产生额外隐私问题。AIM 的一个重要贡献是：利用训练过程中已经产生的差分隐私测量，构造不额外消耗隐私预算的后验高概率误差上界。

6.1 支持的边缘 (supported marginals)

若目标边缘 r 是某个已测量边缘 r_i 的子集，即 $r \subseteq r_i$ ，则可以把高维带噪测量投影到 r ，得到对 $M_r(D)$ 的无偏估计。若多轮测量都支持 r ，可按方差进行加权组合，得到估计量 $\bar{y}_r$ ，其单元方差为：

$$\bar{\sigma}_r^2 = \left[\sum_{i: r \subseteq r_i} \frac{n_r}{n_{r_i} \sigma_i^2} \right]^{-1}$$

其中 n_r 是边缘 r 的单元数， $n_{\{r_i\}}$ 是被测量高阶边缘的单元数， σ_i 是第 i 次高斯测量的噪声标准差。独立测量越多、噪声越小，组合方差通常越低。

对任意 $\lambda \geq 0$ ，论文给出合成数据边缘误差的一侧高概率上界：

$$\|M_r(D) - M_r(\hat{D})\|_1 \leq \|M_r(\hat{D}) - \bar{y}_r\|_1 + \sqrt{2 \ln 2} \bar{\sigma}_r n_r + \lambda \bar{\sigma}_r \sqrt{2 n_r}$$

右侧由两部分组成：第一部分是合成边缘与私有无偏估计之间的可计算差异；后两项是高斯测量不确定性。整个右侧只依赖 AIM 已产生的私有输出和合成数据，因此无需重新查询原始数据。

$$1 - e^{-\lambda^2} = 0.95 \quad \Rightarrow \quad \lambda = \sqrt{\ln 20} \approx 1.73$$

置信上界的含义

95% 上界不是“误差有 95% 概率等于这个数”，而是按机制随机性重复执行时，该上界至少有约 95% 的概率覆盖真实 L1 误差。它通常比观察到的真实误差保守。

6.2 未支持的边缘 (unsupported marginals)

若 r 从未是任何被测量边缘的子集，就没有直接的无偏高斯估计。AIM 利用指数机制的选择保证，把“未被选择的候选通常没有比已选择候选更值得测量”转化为误差界。该界还包含候选集合大小、指数机制隐私参数、边缘权重和选中边缘误差等项，因此通常比 supported marginal 的界更宽。

- supported marginal：有直接测量支持，界通常更紧。
- unsupported marginal：通过选择机制间接推断，界通常更保守。
- 选择用于报告的轮次不能根据哪个界最小而事后挑选，否则覆盖保证会失效；论文建议使用最后一个仍包含该候选的轮次。

7. 推荐的完整评价体系

workload error 是 AIM 的核心指标，但一个可用于实际决策的评价报告不应只包含一个均值。下面给出一套从“与算法目标一致”到“下游任务可用”的分层体系。

层级	建议指标	用途
A. 核心 workload	平均 L1/TV、中位数、P90/P95、最大误差	直接评价 AIM 优化目标
B. 模型与导出	model error、synthetic error、二者差值	区分模型偏差与有限样本误差
C. 边缘结构	一维/二维/三维分组误差；最差边缘列表	定位维度和属性组合问题
D. 数值属性	均值、标准差、分位数、Wasserstein；分箱边界敏感性	弥补 L1 不使用距离结构的缺陷
E. 相关与任务	相关系数差、分类/回归性能、校准误差	验证下游用途
F. 子群与尾部	稀有类别召回、关键子群误差、尾部比例误差	避免平均指标掩盖小群体失败
G. 不确定性	supported/unsupported 后验上界及覆盖水平	在发布后说明哪些查询可信
H. 成本	时间、内存、模型大小、合成行数	评估实际部署可行性

7.1 推荐的评价步骤

- 冻结预处理、属性域、数值分箱和结构零规则。
- 明确主 workload 与独立的测试 workload，避免只评价训练目标。
- 对每个随机种子运行 AIM，保存最终模型和合成表。
- 分别计算 model error 与 synthetic error。
- 按边缘维度、属性组合、单元数和群体频率分组汇总。
- 对关键下游任务进行效用验证，并与简单基线比较。
- 对可支持的查询计算后验高概率误差界。
- 联合报告隐私参数、效用、不确定性和计算成本。

训练 workload 与测试 workload

为了检验泛化能力，可把部分边缘作为 AIM 的目标 workload，把另一组未直接优化的边缘作为测试 workload。若只在训练 workload 上评价，容易高估合成数据的通用性。

7.2 简单基线不可缺少

AIM 的误差应与至少一个简单基线比较，例如独立一维模型、MST、均匀分布或直接发布低阶边缘后拟合的模型。绝对误差为 0.08 是否“好”，取决于相同隐私预算和相同 workload 下其他方法能做到什么。

8. 常见误区与报告模板

常见误区	为什么有问题	正确做法
把 quality score 当最终准确率	它是私有查询选择分数，包含噪声收益项和权重	最终用 workload error 或 TV 评价
混用 L1 与 TV	数值恰好相差一倍	明确是否乘 0.5
只报告平均误差	会隐藏少数严重失败的边缘	增加分位数、最大值和最差列表
只报告合成样本误差	无法判断是模型还是导出造成问题	同时报告 model/synthetic error
不同方法使用不同分箱	评价对象本身不同	固定预处理和域
用同一训练 workload 证明通用可用	只能证明目标统计保存较好	增加独立测试 workload 和下游任务
直接公开基于原始数据的新误差	可能产生额外隐私泄露	使用已纳入预算的 DP 评估或 AIM 后验界
把低边缘误差等同于逐行真实性	边缘约束不能唯一确定联合表	明确合成数据不是原记录复制品

8.1 建议的结果报告模板

项目	应填写的信息
隐私设置	epsilon、delta 或 rho；邻接关系；总预算是否包含预处理
数据设置	记录数、属性数、各属性域、数值分箱、结构零
AIM 设置	workload、权重、轮数、模型容量、合成行数、随机种子数
核心结果	L1 或 TV 口径；平均/中位/P90/最大 workload error
误差分解	平均 model error；平均 synthetic error；导出增量
分组诊断	按 1/2/3-way、属性组合、稀有度的误差
误差上界	覆盖水平；supported/unsupported；上界与点误差的比值
下游效用	任务指标、真实训练测试协议、基线结果
计算成本	运行时间、峰值内存、最终模型大小

一句话总结

评价 AIM 最终合成数据时，核心是目标 workload 上的归一化边缘 L1/TV；可靠报告还必须展示误差分布、模型与抽样误差分解、关键下游任务，以及可计算的后验高概率上界。

附录 A：符号表

符号	解释
D	真实敏感数据集
D_{hat}	最终发布的合成数据集
p_{hat}	Private-PGM 拟合的概率模型
r	一个属性子集，对应一个边缘查询
$M_r(D)$	数据集 D 在 r 上的边缘计数向量
n_r	边缘 r 的直方图单元数量
W	加权边缘查询 workload
c_i	workload 中第 i 个边缘的权重
σ_i	第 i 次高斯测量的噪声标准差
y_{bar_r}	由支持 r 的多个私有测量组合出的无偏估计

附录 B：计算伪代码

输入：真实数据 D 、合成数据 D_{hat} 、workload= $[(r_i, c_i)]$

对每个 (r_i, c_i) ：

$X = \text{marginal_counts}(D, r_i)$

$Y = \text{marginal_counts}(D_{\text{hat}}, r_i)$

$e_i = c_i * \text{sum}(\text{abs}(X - Y)) / \text{len}(D)$

返回：mean(e_i)，并同时计算 median、P90、max

若使用概率与 TV：

$p = X / \text{sum}(X)$

$q = Y / \text{sum}(Y)$

$tv_i = 0.5 * c_i * \text{sum}(\text{abs}(p - q))$

附录 C：参考文献

1. Ryan McKenna, Brett Mullins, Daniel Sheldon, Gerome Miklau. AIM: An Adaptive and Iterative Mechanism for Differentially Private Synthetic Data. Proceedings of the VLDB Endowment, 15(11):2599-2612, 2022. DOI: 10.14778/3551793.3551817.
2. AIM / MBI 官方实现: ryan112358/mbi, mechanisms/aim.py。代码中分别计算 model_errors 与 synth_errors, 并以 $0.5 \times L1$ 输出总变差距离。
3. Ryan McKenna, Gerome Miklau, Daniel Sheldon. Winning the NIST Contest: A Scalable and General Approach to Differentially Private Synthetic Data. Journal of Privacy and Confidentiality, 2021.
4. Yuchao Tao, Ryan McKenna, Michael Hay, Ashwin Machanavajjhala, Gerome Miklau. Benchmarking Differentially Private Synthetic Data Generation Algorithms. AAAI PPAI Workshop, 2022.

资料范围说明

本文聚焦 AIM 原论文中的边缘 workload 效用与误差量化。机器学习、公平性和数值距离等扩展指标属于推荐的工程评价层，不是 AIM 论文对所有任务提供的形式化保证。