

选择强度 β 与邻域尺度 h ：设计与验证

参考记录抽样中两个紧密相关参数的说明

$$\ell(x,z) = \beta F(z) - d(x,z)^2 / (2h^2)$$

对所有候选的 ℓ 做 softmax，得到参考记录的抽样概率。

β 和 h 共同回答同一个问题：当前记录应该向谁学习。 β 强调“候选是否有利”， h 强调“候选是否相近”。

一、选择强度 β

β 控制选择参考记录时有多看重适应度。若两个候选与当前记录距离相同，则它们的概率比只由适应度差决定：

$$P(A) / P(B) = \exp[\beta(F_A - F_B)]$$

直观含义：

- $\beta = 0$ ：完全忽略适应度，只看距离。
- β 较小：高适应度候选只是略占优势。
- β 较大：抽样集中到少数高适应度候选。

示例：若 $F_A - F_B = 0.1$ ，则：

β	概率倍率 $\exp(0.1\beta)$	解释
1	约 1.11	优势很弱
10	约 2.72	优势明显
50	约 148	几乎只选 A

推荐设计方法

不要直接猜一个固定数值。先计算当前所有记录的适应度，并取一个典型适应度差：

$$\Delta F = Q_{90}(F) - Q_{10}(F)$$

再规定高适应度记录希望获得多少倍优势。若希望约 3 倍：

$$\beta = \ln(3) / \Delta F$$

推荐起点：在距离相同时，让典型高适应度记录相对典型低适应度记录具有约 3 倍选择优势。

如何验证 β

- 构造两个距离完全相同、适应度不同的候选。
- 重复抽样，例如 10,000 次。
- 检查经验频率比是否接近理论概率比。
- 逐步增大 β ，确认高适应度候选的优势按预期增强。

异常表现

情况	可观察现象	含义
β 太小	高低适应度记录被选次数接近；查询误差下降慢	选择近似随机
β 太大	少数 donor 被反复选中；多样性快速下降；容易过冲	选择过度集中

二、邻域尺度 h

h 控制当前记录愿意参考多远的候选。距离对应的相似度权重为：

$$\text{similarity}(x,z) = \exp[-d(x,z)^2 / (2h^2)]$$

- h 小：强烈偏爱近邻。
- h 大：远近差别减弱。
- h 非常大：距离几乎不再起作用。

使用 h 之前必须先统一距离尺度

年龄是整数，其他属性是类别。如果直接把年龄差 20 与类别不同记作 1 相加，年龄会支配全部距离。建议先归一化：

$$d_{\text{age}}(x,z) = |\text{age}_x - \text{age}_z| / 67$$

其他类别属性可定义为：相同记 0，不同记 1。最后对 10 个属性的距离求平均，使总距离大致落在 0 到 1。

推荐设计方法

计算数据中大量记录对的距离，并得到距离分位数 D_{25} 、 D_{50} 、 D_{75} 。

$$\text{推荐起点：} h = D_{50}$$

随后比较三种邻域：

- $h = D_{25}$ ：偏局部。
- $h = D_{50}$ ：中等范围。
- $h = D_{75}$ ：较宽范围。

如何验证 h

- 让所有候选适应度完全相同，只改变它们与当前记录的距离。
- 设置近、中、远三个候选，例如距离为 0.1、0.3、0.6。
- 重复抽样，检查距离越近是否越容易被选。
- 减小 h 时，近邻占比应明显上升；增大 h 时，距离差异应减弱。

异常表现

情况	可观察现象	含义
h 太小	几乎只抽到自己或完全相同记录；更新长期停滞	邻域过窄
h 太大	远距离 donor 经常被选；更新跨度大；结构不自然	邻域过宽

三、为什么 β 和 h 必须联合测试

β 偏向“更有用的记录”，h 偏向“更相近的记录”。假设候选 A 适应度高但距离远，候选 B 适应度一般但距离近，最终选择由两部分共同决定：

$$\beta(F_A - F_B) \text{ 与 } (d_A^2 - d_B^2) / (2h^2)$$

组合	主要倾向	风险
β 大, h 大	强烈追求高适应度，远候选也可能被选	选择集中、跳跃较大
β 小, h 小	几乎只看近邻	可能长期停滞
β 大, h 小	只在近邻中强烈偏向高适应度	较稳，但可能错过必要远邻
β 小, h 大	适应度和距离都不突出	接近随机选择

最简单的联合实验

选择 3 种适应度强度和 3 种邻域范围，形成 9 组实验：

	h = D ₂₅	h = D ₅₀	h = D ₇₅
适应度倍率 1.5	组 1	组 2	组 3
适应度倍率 3	组 4	组 5	组 6
适应度倍率 6	组 7	组 8	组 9

每组至少观察以下四项：

- 查询误差是否持续下降。
- 抽到的 donor 平均距离。

- 是否被少数 donor 垄断。
- 记录多样性是否快速下降。

推荐起点

$$\beta = \ln(3) / [Q_{90}(F) - Q_{10}(F)]$$

$$h = D_{50}$$

含义：典型高适应度记录约有 3 倍优势，同时在中等邻域范围内学习。