

基于查询残差的表格扩散演化生成器

完整方法设计（只讨论生成器，不讨论测量、隐私预算和定向候选搜索）

方法讨论稿

2026-07-15

目录

1	给第一次读这份方案的人	3
2	方法边界与输入输出	4
2.1	输入	4
2.2	输出	5
2.3	最终希望达到的状态	5
3	用最简单的话理解整个过程	6
3.1	把每条记录看成一个个体	6
3.2	查询误差决定什么样的记录“更值得繁殖”	6
3.3	每条记录的变化仍然是随机的	6
3.4	为什么每条记录一轮只生成一个下一状态就够了	7
4	查询表示、当前答案和残差	7
4.1	单条记录对查询的贡献	7
4.2	当前整张表的查询答案	7
4.3	原始残差	7
4.4	噪声容忍后的有效残差	8
4.5	查询权重	8
5	适应度怎样设计	8
5.1	适应度要回答的不是“这条记录现在要改成什么”	8
5.2	第一步：看一条记录是否顺着残差方向	9
5.3	第二步：防止一条记录对太多查询同时做过大改变	9
5.4	为什么这个公式不是随便拍出来的	10
5.5	一个四状态的具体例子	10
5.6	把可能为负的适应度变成抽样权重	11

6	为什么还需要“相近程度”	12
6.1	不能让所有记录都直接模仿全局最高分记录	12
6.2	把属性分成合法变化块	12
6.3	记录距离	12
6.4	每条记录怎样抽一个参考记录	13
6.5	参考记录池不是多候选	13
7	一条记录怎样向参考记录靠近一步	14
7.1	三个简单动作	14
7.2	记录参与概率 ρ_t	14
7.3	属性块复制概率 η_t	14
7.4	变异概率 μ_t	14
7.5	最终合法性检查	15
7.6	一条记录在一轮中的输出	15
8	一轮完整扩散演化会发生什么	15
8.1	第 1 步：计算当前查询答案	15
8.2	第 2 步：计算残差和当前损失	16
8.3	第 3 步：计算每条记录的查询贡献	16
8.4	第 4 步：计算所有记录的适应度	16
8.5	第 5 步：建立共享参考记录池	16
8.6	第 6 步：每条记录只抽一个参考记录	17
8.7	第 7 步：每条记录生成一个下一状态	17
8.8	第 8 步：整代安全检查	17
8.9	第 9 步：更新并进入下一轮	17
9	全部主循环伪代码	18
10	各个参数是什么意思	19
10.1	与查询和噪声有关的参数	19
10.2	与参考记录选择有关的参数	20
10.3	与一轮移动幅度有关的参数	20
10.4	运行和停止参数	20
11	参数随轮数怎样变化	21
12	每一轮应该记录什么	21
12.1	残差方向漂移	22
12.2	适应度熵	22
12.3	实际变化率	23

1 给第一次读这份方案的人	3
13 常见失败现象与处理	23
14 为什么这条路线仍然是扩散演化，而不是定向演化	23
14.1 残差是否直接指定了某条记录的目标状态	23
14.2 是否为每个活跃查询寻找源记录	23
14.3 是否逐条选择收益最大的动作	23
14.4 一条记录是否可以偶尔朝非最优方向变化	24
15 与原始 Diffusion Evolution 的对应关系	24
16 计算量与大数据实现	24
16.1 小规模正确性版本	24
16.2 真实数据版本	24
16.3 查询贡献计算	24
17 停止条件	25
18 最终结果应如何解释	25
19 第一版最小可运行配置	26
20 参考文献与内部材料	26
21 附录 A：适应度与平均真实替换收益的推导	27
22 附录 B：术语对照	28

1 给第一次读这份方案的人

这份文档只回答一个问题：

已经有一张初始合成表，也已经有一组查询目标以后，怎样让表中的所有记录按照查询误差形成的“适应度”反复演化，最后得到一张查询结果更接近目标的合成表？

这份方案**不做**下面这些事情：

- 不讨论差分隐私预算如何分配；
- 不讨论查询如何选择、如何测量、如何投影；
- 不按某个查询逐条寻找“哪条记录应该改成什么”；
- 不为每条记录生成许多候选再贪心挑一个；
- 不建立候选-查询二部图，不做 L0/L1/L2 定向候选；
- 不逐条接受、更新残差、再选择下一条记录。

本文真正要做的是：

1. 当前整张表先计算一次查询误差;
2. 根据这些误差, 给每一种当前记录形态计算一个适应度;
3. 每条记录观察当前种群中“适应度高而且与自己相近”的记录;
4. 每条记录只抽取一个参考记录, 并随机向它靠近一步;
5. 所有记录同步完成这一轮;
6. 重新计算查询误差, 再开始下一轮;
7. 反复进行, 直到查询误差进入允许范围, 或者继续迭代已没有明显改善。

一句话概括:

残差不是用来直接指定“第几条记录改成什么”, 而是用来形成一个适应度地形; 所有记录在这个适应度地形上做有方向的随机演化。

原始论文《Diffusion Models are Evolutionary Algorithms》把反向扩散解释为一种演化过程: 当前种群先计算适应度, 每个个体再根据邻居的适应度估计更好的状态, 并通过逐步去噪产生下一代。官方代码的典型循环也是“计算当前种群适应度 -> 生成下一代”, 而不是“每个个体生成许多候选 -> 取其中最优”。本文把这一思想改造成适用于表格记录和查询残差的生成器。[1][2]

当前已有的 V3.0 文档把搜索单位定义为明确的记录修改动作, 并通过 L0/L1/L2 构造目标记录, 再逐个计算动态收益。那是一条可以独立研究的定向局部搜索路线; 本文不否定它, 但不把它作为扩散演化生成器的主线。[3][4]

2 方法边界与输入输出

2.1 输入

生成器只接收以下内容:

1. 初始合成表

$$S_0 = \{x_1, x_2, \dots, x_N\}.$$

表的行数固定为 N 。每一条记录都必须已经合法。

2. 固定查询集合

$$Q = \{q_1, q_2, \dots, q_m\}.$$

每个查询都能对单条记录返回 0 或 1。例如:

- 年龄在 20 到 30 岁;
- 职业是教师;
- 性别为女且学历为本科;
- 某个低阶合取条件成立。

3. 每个查询的目标值

$$y = (y_1, y_2, \dots, y_m).$$

目标值可以是经过差分隐私测量和一致性处理后的计数。本方案不负责产生这些目标。

4. 可选的噪声标准差

$$\sigma_1, \dots, \sigma_m.$$

如果不知道噪声尺度，第一版可以统一令 $\sigma_j = 1$ 。

5. 记录合法规则

包括：

- 每个属性的允许取值；
- 哪些属性不能修改；
- 哪些属性必须作为一个合法组合整体变化；
- 一个函数 `is_valid(row)`，用于最终检查整条记录是否合法。

2.2 输出

生成器输出：

1. 一张与初始表行数相同的最终合成表 S_{best} ；
2. 每轮查询答案、残差和损失；
3. 每轮记录适应度；
4. 每轮有多少记录发生变化；
5. 每轮参考记录的平均距离；
6. 最终停止原因；
7. 用于复现实验的随机种子和参数配置。

2.3 最终希望达到的状态

理想情况下，算法停止时会同时出现下面几种现象：

- 大多数查询答案已经接近目标；
- 查询误差进入允许的噪声范围；
- 不同记录之间的适应度差异变小；
- 每轮真正发生变化的记录越来越少；
- 表的整体分布逐渐稳定；
- 所有记录始终合法；
- 最终输出的是完整表，而不是一批待选择的候选动作。

如果查询目标彼此冲突、合法记录空间无法实现目标，或者查询覆盖不足，算法不保证所有残差都变为 0。此时输出运行过程中损失最低的表，并报告仍未拟合的查询。

3 用最简单的话理解整个过程

3.1 把每条记录看成一个个体

一张包含 5 万条记录的合成表，就是一个包含 5 万个个体的种群。

每个个体不是一个连续向量，而是一条表格记录。例如：

年龄段 = 30-39

学历 = 本科

职业 = 教师

婚姻 = 已婚

3.2 查询误差决定什么样的记录“更值得繁殖”

假设当前有两个查询：

q1: 学历 = 本科

q2: 职业 = 教师

当前表中：

- 本科记录太少；
- 教师记录太多。

那么：

- “本科且不是教师”的记录应该获得较高适应度；
- “不是本科且是教师”的记录应该获得较低适应度；
- 同时影响多个查询的记录，要综合所有正面和负面作用。

这里没有人提前指定“第 1024 条记录必须变成本科非教师”。算法只是在概率上让“本科非教师”这种记录更容易成为其他记录的参考对象。

3.3 每条记录的变化仍然是随机的

随机不代表没有方向。

可以把它理解为一枚有偏硬币：

- 单次结果仍然有随机性；
- 但正面概率如果是 0.8，抛很多次以后，整体趋势非常明确。

扩散演化也是这样：

- 某一条记录这轮可能没变；
- 某一条记录可能偶尔朝不理想的方向变化；
- 但几万条记录共同抽样以后，整张表在平均意义上应朝降低残差的方向移动；

- 下一轮又会根据新的残差重新计算适应度，所以方向会自动纠正。

3.4 为什么每条记录一轮只生成一个下一状态就够了

因为我们不是从一个与残差无关的随机分布中先随便抽，再事后打分。

我们直接从一个已经包含下面两类信息的分布中抽样：

1. 哪些记录当前适应度高；
2. 哪些高适应度记录与当前记录比较接近。

只要这个抽样分布本身方向正确，每条记录每轮抽一次就够了。几万条记录和多轮迭代共同构成了大量抽样。

文中后面出现的“参考记录池”不是为每条记录生成许多候选。它只是让每条记录看到一小部分当前种群，从中只抽一个参考记录，然后只产生一个下一状态。

4 查询表示、当前答案和残差

4.1 单条记录对查询的贡献

对第 j 个查询，定义：

$$a_j(x) = \begin{cases} 1, & x \text{ 满足查询 } q_j, \\ 0, & x \text{ 不满足查询 } q_j. \end{cases}$$

把一条记录对全部查询的贡献写成向量：

$$a(x) = (a_1(x), a_2(x), \dots, a_m(x)).$$

4.2 当前整张表的查询答案

$$q_j(S) = \sum_{i=1}^N a_j(x_i).$$

本文第一版统一使用计数，不要在同一套公式里混用计数和比例。

4.3 原始残差

定义：

$$e_j = y_j - q_j(S).$$

解释：

- $e_j > 0$: 当前答案偏低, 需要增加满足该查询的记录;
- $e_j < 0$: 当前答案偏高, 需要减少满足该查询的记录;
- $e_j = 0$: 当前正好匹配。

注意符号必须固定。全文都使用“目标减当前答案”。

4.4 噪声容忍后的有效残差

如果目标本身有高斯噪声, 不应该把很小的误差也反复拟合。定义:

$$r_j = \text{sign}(e_j) \max(|e_j| - \kappa\sigma_j, 0).$$

参数 κ 的含义:

- $\kappa = 0$: 完全不设置容忍区, 适合最初的无噪声单元测试;
- $\kappa = 1$: 误差小于一个标准差时不再推动;
- $\kappa = 1.645$: 约对应双侧 90% 的高斯范围;
- $\kappa = 1.96$: 约对应双侧 95% 的高斯范围。

初次实现时必须先用 $\kappa = 0$ 跑通。核心正确后, 再加入噪声容忍。

4.5 查询权重

噪声越小的查询通常越可信, 因此可令:

$$w_j = \frac{1}{\sigma_j^2 + \sigma_{\min}^2}.$$

为了避免所有权重整体太大或太小, 再归一化为平均值 1:

$$w_j \leftarrow \frac{mw_j}{\sum_{k=1}^m w_k}.$$

如果第一版没有噪声信息, 直接令所有 $w_j = 1$ 。

5 适应度怎样设计

5.1 适应度要回答的不是“这条记录现在要改成什么”

适应度回答的是:

在当前查询残差下, 这种记录形态是否值得在下一代中变得更常见?

这与定向编辑的区别非常重要。

- 定向编辑分数通常依赖“源记录 x_i 改成目标记录 u ”这一对动作;

- 扩散演化的个体适应度首先只评价某一种当前记录形态 z 的繁殖价值；
- 某条记录最终向谁学习，还要结合二者的相似程度随机决定。

5.2 第一步：看一条记录是否顺着残差方向

当前种群在第 j 个查询上的平均贡献是：

$$\bar{a}_j = \frac{1}{N} \sum_{i=1}^N a_j(x_i) = \frac{q_j(S)}{N}.$$

对记录 z ，定义相对平均贡献：

$$a_j(z) - \bar{a}_j.$$

它的意义是：

- 大于 0：这种记录比当前平均水平更容易满足查询 j ；
- 小于 0：这种记录比当前平均水平更不容易满足查询 j 。

把它与有效残差相乘：

$$w_j r_j (a_j(z) - \bar{a}_j).$$

四种情况：

当前情况	记录情况	乘积倾向
查询偏低, $r_j > 0$	记录满足查询	加分
查询偏低, $r_j > 0$	记录不满足查询	减分
查询偏高, $r_j < 0$	记录满足查询	减分
查询偏高, $r_j < 0$	记录不满足查询	加分

把所有查询相加，得到最简单的方向分数：

$$D_t(z) = \sum_{j=1}^m w_j r_j (a_j(z) - \bar{a}_j).$$

这个分数已经能够把全部查询残差汇总到一条记录上。

5.3 第二步：防止一条记录对太多查询同时做过大改变

只用 $D_t(z)$ 时，一种极端记录可能因为同时满足很多当前偏低的查询而获得很高分，但让它大量繁殖可能造成过冲。

因此加入一个固定的步幅惩罚：

$$P_t(z) = \frac{1}{2} \sum_{j=1}^m w_j (a_j(z) - \bar{a}_j)^2.$$

最终原始适应度为：

$$F_t(z) = \sum_{j=1}^m w_j r_j (a_j(z) - \bar{a}_j) - \frac{1}{2} \sum_{j=1}^m w_j (a_j(z) - \bar{a}_j)^2$$

直观解释：

适应度

- = 这类记录能把查询误差往正确方向推多少
- 一条记录可能造成的过大跳动

当某个查询已经进入噪声容忍区时，它的有效残差为 0，因此不再给出“应该增加还是减少”的方向；二次项仍然会提醒算法不要把已经较稳定的查询一次破坏得太多。第一版无噪声验证中使用 $\kappa = 0$ ，此时公式具有下面的精确平均收益解释。

5.4 为什么这个公式不是随便拍出来的

先暂时令 $\kappa = 0$ ，即 $r = e$ ，并使用加权平方误差：

$$L(S) = \frac{1}{2} e^\top W e.$$

把一条随机选择的当前记录替换成记录形态 z ，可以计算真实损失下降量。对“被替换的是哪一条记录”取平均以后，得到：

$$\text{平均真实下降量} = F_t(z) + C_t,$$

其中 C_t 对所有 z 都是同一个常数。

因为比较适应度时相同常数不影响排序，所以：

$F_t(z)$ 等价于“让这种记录作为繁殖参考时，随机替换一条当前记录能够带来的平均损失下降”。

这给出了一个非常重要的单元测试：程序计算出的 $F_t(z)$ ，必须与暴力枚举得到的平均真实替换收益只差同一个常数。

加入 $\kappa > 0$ 的噪声容忍以后，上式不再是全局目标的严格恒等式，但仍然是以“超出噪声范围的残差”为方向的局部适应度。

5.5 一个四状态的具体例子

假设属性 $A, B \in \{0, 1\}$ ，当前种群恰好有四条记录：

00, 01, 10, 11

查询为:

q1: $A = 1$

q2: $B = 1$

q3: $A = 1$ 且 $B = 1$

当前答案:

$$q(S) = (2, 2, 1).$$

目标答案:

$$y = (3, 1, 1).$$

因此:

$$r = (1, -1, 0).$$

当前平均贡献:

$$\bar{a} = (0.5, 0.5, 0.25).$$

所有查询权重取 1, 按最终公式可得到:

记录形态	原始适应度 F
00	-0.28125
01	-1.28125
10	0.71875
11	-0.53125

最高的是 10, 因为当前需要增加 $A = 1$, 同时减少 $B = 1$ 。这个结果完全符合直觉。

5.6 把可能为负的适应度变成抽样权重

抽样概率必须为正。先标准化:

$$z_i = \frac{F_t(x_i) - \text{mean}(F_t)}{\text{std}(F_t) + \varepsilon}.$$

再把它变成正权重:

$$b_i = \exp \left(\text{clip} \left(\frac{z_i}{\tau_t}, -8, 8 \right) \right).$$

参数 τ_t 叫作“选择温度”，用普通话解释就是：

- τ_t 大：高分和低分的差别被压平，探索更多；
- τ_t 小：更强烈偏向高适应度记录；
- 太小会导致少数记录过度复制；
- 太大会导致适应度几乎不起作用。

如果全部适应度几乎相同，就令所有 $b_i = 1$ 。这通常表示残差已很小，或者查询实现有问题。

6 为什么还需要“相近程度”

6.1 不能让所有记录都直接模仿全局最高分记录

如果只按适应度选择参考记录，**全表可能迅速坍缩成少数几种记录**，丢失多样性，也可能一次改变太多属性。

原始扩散演化的重要思想之一是：

一个个体主要向自己附近的高适应度个体学习。

在表格中，“附近”就是记录比较相似。

6.2 把属性分成合法变化块

不要一开始就把每个字段都当成完全独立的变化单位。

建议把属性分成若干块：

块 1：年龄段

块 2：学历

块 3：职业

块 4：婚姻状态

块 5：一组必须共同合法的关联字段

如果两个字段必须一起变化才能保持合法，就把它们放在同一个块里。

6.3 记录距离

对第 g 个**属性块**，定义**局部距离** δ_g ：

- 普通类别块：相同为 0，不同为 1；
- 合法模板块：模板相同为 0，不同为 1；
- 已归一化的数值块：使用绝对差；
- 不可修改块：不进入距离，也不允许变化。

整体距离：

$$d(x, z) = \frac{\sum_g \omega_g \delta_g(x_g, z_g)}{\sum_g \omega_g}.$$

这样 $d(x, z)$ 通常位于 0 到 1 之间。

6.4 每条记录怎样抽一个参考记录

设当前记录为 x_i ，可供观察的参考记录集合为 D_t 。对其中第 k 条参考记录 z_k ，定义抽样分数：

$$\ell_{ik} = \frac{z_k^{\text{fitness}}}{\tau_t} - \frac{d(x_i, z_k)^2}{2h_t^2}.$$

这里的 z_k^{fitness} 是前面标准化后的适应度，不是记录本身。

抽样概率：

$$\Pr(J_i = k) = \frac{\exp(\ell_{ik})}{\sum_{l \in D_t} \exp(\ell_{il})}.$$

然后每条记录只抽一次：

$$z_i^* = z_{J_i}.$$

参数 h_t 表示“允许观察多远的记录”：

- h_t 大：较远的高适应度记录也能被看到；
- h_t 小：主要向非常相似的记录学习；
- 前期可以大一些，帮助全局探索；
- 后期逐渐变小，进行局部精修。

6.5 参考记录池不是多候选

对于小实验，可以让每条记录观察全部 N 条记录。

真实数据有几万行时，全部两两比较会很慢，因此每轮建立一个共享参考池，例如 512 条记录：

- 75% 从当前表均匀抽取，保留多样性；
- 25% 取当前适应度较高的记录，保证好模式不会遗漏。

每条记录只是对这 512 条参考记录计算概率，最后仍然只抽取一个参考记录、产生一个下一状态。

7 一条记录怎样向参考记录靠近一步

7.1 三个简单动作

对当前记录 x_i 和抽到的参考记录 z_i^* ，本轮只做下面三件事：

1. 可能保持不变；
2. 可能复制参考记录的一部分属性块；
3. 以很小概率发生随机合法变异。

7.2 记录参与概率 ρ_t

先抽一个伯努利变量：

$$U_i \sim \text{Bernoulli}(\rho_t).$$

- 如果 $U_i = 0$ ，本轮整条记录保持不变；
- 如果 $U_i = 1$ ，进入属性块复制过程。

ρ_t 控制一轮中大约有多少比例的记录有机会变化。

例如：

- $N = 50000$;
- $\rho_t = 0.02$;

那么平均约有 1000 条记录进入更新过程。

7.3 属性块复制概率 η_t

对每个可修改属性块 g ：

- 如果当前记录与参考记录在该块相同，直接保持；
- 如果不同，则以概率 η_t 复制参考记录的该块；
- 以概率 $1 - \eta_t$ 保持原值。

这使记录不是一步完整复制参考记录，而是逐步靠近。

7.4 变异概率 μ_t

只靠复制当前已有记录，永远无法发现当前种群中完全不存在的新状态。因此需要小概率变异。

建议第一版采用“每条参与更新的记录最多变异一个块”：

1. 以概率 μ_t 决定是否变异；
2. 随机选择一个可修改块；
3. 从该块的合法先验分布中抽一个值；

4. 完整检查记录合法性;
5. 不合法则重抽几次, 仍失败就取消变异。

合法先验可以来自:

- DP 1-way 初始化分布;
- 公开统计;
- 合法值上的均匀分布。

7.5 最终合法性检查

生成新记录 u_i 后:

```
if is_valid(u_i):
```

保留 u_i

```
else:
```

重试少量次数

仍失败则回到 x_i

第一版更推荐通过“合法属性块”尽量从结构上保证合法, 而不是大量生成后再拒绝。

7.6 一条记录在一轮中的输出

每条记录只产生:

当前记录 x_i

参考记录 z_i *

下一状态 u_i

是否参与更新

复制了哪些属性块

是否发生变异

最终是否合法

没有 L0/L1/L2 候选列表, 也没有“前 10 个候选”。

8 一轮完整扩散演化会发生什么

下面给出一轮中每一步的输入、处理和输出。

8.1 第 1 步: 计算当前查询答案

输入: 当前表 S_t 。

输出:

$$q_t = (q_1(S_t), \dots, q_m(S_t)).$$

8.2 第 2 步：计算残差和当前损失

输出：

$$e_t = y - q_t, \quad r_t = \text{噪声容忍后的有效残差}.$$

定义监控损失：

$$E(S_t) = \frac{1}{2} \sum_{j=1}^m w_j [\max(|e_{j,t}| - \kappa \sigma_j, 0)]^2.$$

这一步回答：当前还有哪些查询没有拟合好，误差有多大。

8.3 第 3 步：计算每条记录的查询贡献

输出一个 $N \times m$ 的 0/1 矩阵：

$$A_{ij} = a_j(x_i).$$

以及当前平均贡献：

$$\bar{a} = \frac{1}{N} \sum_i A_i.$$

8.4 第 4 步：计算所有记录的适应度

对每条记录计算 $F_t(x_i)$ ，再标准化得到适应度分数。

输出：

```
raw_fitness[N]
standardized_fitness[N]
positive_weight[N]
```

8.5 第 5 步：建立共享参考记录池

小实验：使用全体记录。

大数据：建立大小为 M 的参考池。

输出：


```
donor_ids[M]
donor_rows[M]
donor_fitness[M]
```

8.6 第 6 步：每条记录只抽一个参考记录

根据“参考记录适应度 + 与当前记录的相似度”形成概率。

输出：

```
chosen_donor_id[N]
chosen_donor_distance[N]
```

8.7 第 7 步：每条记录生成一个下一状态

通过参与概率、属性块复制和小概率变异，得到：

$$U_t = \{u_1, u_2, \dots, u_N\}.$$

这是一张完整的“下一代表格提案”。

8.8 第 8 步：整代安全检查

计算下一代表格的损失 $E(U_t)$ 。

- 如果 $E(U_t) \leq E(S_t)$ ，接受整代；
- 如果损失明显上升，说明本轮改变太多，减小 ρ_t 后重新抽样；
- 最多重试若干次；
- 仍不能下降时，本轮保持原表，并记录停滞。

这里检查的是整张下一代表格，不是逐条挑选候选。

它只回答“这一步迈得是不是太大”，不回答“第几条记录应该被精确修改”。因此它不会把方法重新变成定向贪心。

8.9 第 9 步：更新并进入下一轮

若整代被接受：

$$S_{t+1} = U_t.$$

重新计算查询答案和适应度，继续下一轮。

9 全部主循环伪代码

```

S = initial_table
best_S = S.copy()
best_loss = evaluate_loss(S)

for t in range(num_rounds):
    # 1. 用当前整张表计算查询答案和残差
    A = evaluate_all_rows_on_queries(S)          # shape: [N, m]
    q = A.sum(axis=0)
    raw_residual = target - q
    active_residual = remove_noise_tolerance(raw_residual)
    loss = workload_loss(raw_residual)

    # 2. 根据同一份当前残差, 计算全部记录适应度
    fitness = compute_individual_fitness(
        A=A,
        active_residual=active_residual,
        query_weights=query_weights,
    )
    normalized_fitness = standardize(fitness)

    # 3. 建立这一轮共享参考记录池
    donor_ids = build_shared_donor_pool(
        fitness=fitness,
        pool_size=M,
        random_fraction=0.75,
    )

    # 4. 每条记录根据“适应度 + 相近程度”只抽一个参考记录
    chosen_donor_ids = sample_one_donor_per_row(
        rows=S,
        donor_rows=S[donor_ids],
        donor_fitness=normalized_fitness[donor_ids],
        temperature=tau[t],
        neighbor_radius=h[t],
    )

```

```

# 5. 每条记录只产生一个下一状态
proposal = evolve_all_rows_once(
    rows=S,
    chosen_donors=S[chosen_donor_ids],
    update_rate=rho[t],
    copy_rate=eta[t],
    mutation_rate=mu[t],
    schema=schema,
    rng=rng,
)

# 6. 整代检查，而不是逐条贪心选择
proposal_loss = evaluate_loss(proposal)

if proposal_loss <= loss + numerical_tolerance:
    S = proposal
else:
    # 只缩小全局步幅，再重新抽一整代
    S = retry_with_smaller_update_rate_or_keep_current(S)

# 7. 永远保存运行中最好的完整表
current_loss = evaluate_loss(S)
if current_loss < best_loss:
    best_loss = current_loss
    best_S = S.copy()

if stopping_condition_met():
    break

return best_S, diagnostics

```

10 各个参数是什么意思

10.1 与查询和噪声有关的参数

参数	含义	太小会怎样	太大会怎样	第一版建议
κ	噪声容忍倍数	容易拟合噪声	太多查询不再提供方向	无噪声测试用 0; 之后比较 1、1.645
$\sigma_{\min}$	防止噪声方差为 0	数值不稳定	权重差异被过度压平	按查询计数尺度设一个很小正数
w_j	查询可信度	可信查询影响不足	单个查询支配全部演化	先全部取 1, 再接入逆方差

10.2 与参考记录选择有关的参数

参数	普通话解释	太小会怎样	太大会怎样	建议起点
τ_t	对高适应度记录偏爱多强	过度复制少数模式	适应度几乎不起作用	从 2.0 缓慢降到 0.7
h_t	一条记录能观察多远	只能看到极近记录, 移动慢	容易跨很远, 破坏结构	归一化距离下从 0.8 降到 0.15
M	共享参考池大小	概率近似粗, 可能漏模式	速度和内存开销大	先 256 或 512
top_fraction	参考池中高适应度记录比例	好模式可能漏掉	多样性下降	0.25

10.3 与一轮移动幅度有关的参数

参数	普通话解释	太小会怎样	太大会怎样	建议起点
ρ_t	一轮中多少记录有机会变化	收敛慢	大批量过冲	0.02 到 0.10 起步, 后期降到 0.005 到 0.02
η_t	参与记录复制多少参考属性块	每次几乎不动	一次复制太多, 像整行替换	前期 0.3 到 0.6, 后期 0.05 到 0.2
μ_t	发现新状态的变异概率	缺失模式永远不出现	随机噪声过大	前期 0.005 到 0.02, 后期 0.0005 到 0.005
max_retry	整代损失上升时最多重抽次数	容易放弃可改善轮次	时间浪费	3 到 5

10.4 运行和停止参数

参数	含义	建议起点
T	最大轮数	玩具实验 50 到 200; 真实数据 100 到 500
patience	连续多少轮几乎不改善就停止	10 到 30
min_relative_improvement	最小相对改善	10^{-5} 到 10^{-4}
min_change_rate	记录变化率低于该值可视为稳定	10^{-4} 到 10^{-3}
seed	随机种子	必须保存, 至少报告 5 个种子

所有数值只是第一轮实验的起点, 不是论文结论。参数必须通过消融实验确认。

11 参数随轮数怎样变化

设总轮数为 T , 当前进度:

$$s_t = \frac{t}{T - 1}.$$

对需要**从大到小**变化的参数, 使用最简单的线性计划:

$$v_t = (1 - s_t)v_{\text{start}} + s_tv_{\text{end}}.$$

建议:

- 邻近范围 h_t : 大到小;
- 选择温度 τ_t : 大到中等偏小;
- 记录参与率 ρ_t : 大到小;
- 属性块复制率 η_t : 大到小;
- 变异率 μ_t : 大到小。

对应的行为:

前期: 看得远、变化较多、允许探索新状态
中期: 高适应度模式逐渐扩散, 查询残差快速下降
后期: 只向相近记录小步学习, 变异变少, 避免来回震荡

第一版不要同时尝试复杂的余弦计划、自适应温度和多个控制器。先证明最简单计划能工作。

12 每一轮应该记录什么

至少保存下面这些信息:

```

round
loss
raw_residual_l2
active_residual_l2
max_abs_residual
num_active_queries
fitness_mean
fitness_std
fitness_max
fitness_entropy
mean_donor_distance
p90_donor_distance
proposed_change_rate
accepted_change_rate
mutation_count
invalid_proposal_count
generation_retry_count
update_rate_used

```

其中几个特别重要的诊断：

12.1 残差方向漂移

令：

$$\Delta q_t = q(S_{t+1}) - q(S_t).$$

计算：

$$\text{directional drift} = r_t^\top W \Delta q_t.$$

它大于 0，表示这一代整体在有效残差方向上移动。

12.2 适应度熵

如果几乎所有概率集中在少数记录上，说明选择过强，可能模式坍缩。此时应增大 τ_t 、增大参考池的随机比例，或者增大 h_t 。

12.3 实际变化率

提案变化率和最终接受变化率差别很大，说明非法提案或整代回退太多，需要检查属性块设计和步幅。

13 常见失败现象与处理

现象	最可能原因	先做什么
损失上下剧烈震荡	ρ_t 或 η_t 太大	先把 ρ_t 减半
损失几乎不动	选择温度太高、更新率太低、残差符号写反	用四状态玩具测试检查适应度排序
全表迅速只剩少数记录形态	τ_t 太小，参考池高分比例太高	增大温度和随机参考比例
罕见联合状态始终不出现	变异太低，必须共同变化的字段未成块	增加合法块变异，而不是改成定向搜索
非法记录很多	属性块划分错误，只做了单字段合法	把相关字段合并成合法模板块
查询进入容忍区后仍被持续推动	有效残差实现错误	检查 $r_j = 0$ 是否真的不进入适应度
所有适应度相同但残差很大	查询贡献矩阵错误或残差没有传入	逐条打印玩具数据的 A 、 r 、 F
真实数据速度太慢	使用了全体两两距离	改用固定大小共享参考池
整代经常被拒绝	同步变化太多	降低 ρ_t ，必要时也降低 η_t

14 为什么这条路线仍然是扩散演化，而不是定向演化

可以按四个问题判断。

14.1 残差是否直接指定了某条记录的目标状态

本文：没有。

残差只形成适应度。目标状态通过随机观察高适应度近邻后产生。

14.2 是否为每个活跃查询寻找源记录

本文：没有。

所有记录都在同一轮中计算适应度和抽样。

14.3 是否逐条选择收益最大的动作

本文：没有。

整代同步产生，只在整张表层面控制步幅。

14.4 一条记录是否可以偶尔朝非最优方向变化

本文：可以。

这保留了随机探索和变异。算法要求的是种群整体在期望上朝正确方向漂移，而不是每条记录每一步都严格改善。

15 与原始 Diffusion Evolution 的对应关系

原始演化概念	本文表格生成器中的对应物
population	当前合成表的全部记录
fitness	查询残差形成的个体适应度
selection	高适应度记录更容易被抽为参考记录
reproductive isolation / neighborhood	相似记录之间更容易相互学习
denoising	当前记录逐块向参考记录靠近
mutation / noise	小概率合法块变异
diffusion schedule	邻近范围、更新率、复制率、变异率逐步减小
next generation	一轮同步生成的完整下一张表

16 计算量与大数据实现

16.1 小规模正确性版本

对 N 条记录全部两两计算距离：

$$O(N^2G).$$

只适合几十到几千条记录的玩具实验。

16.2 真实数据版本

使用大小固定为 M 的共享参考池：

$$O(NMG).$$

当 $M = 512$ 时，计算量随记录数 N 近似线性增长。

16.3 查询贡献计算

最初可以每轮完整计算 $N \times m$ 查询矩阵，确保正确。

后续再做优化：

- 只重新计算发生变化的记录；
- 缓存每条记录的查询贡献；
- 对重复记录压缩为“唯一记录 + 出现次数”；
- 使用 NumPy 或 PyTorch 批量计算；
- 按查询依赖属性减少无关计算。

这些是性能优化，不改变生成方法本身。

17 停止条件

满足任意一个即可停止：

1. 所有有效残差都为 0；
2. 连续 **patience** 轮相对改善低于阈值；
3. 连续多轮实际记录变化率很低；
4. 达到最大轮数或时间预算；
5. 整代步幅已经很小，仍无法得到更低损失。

停止时输出运行过程中损失最小的完整表，而不一定只输出最后一轮。

18 最终结果应如何解释

算法最终得到的不是“把每个查询分别修好的一组动作”，而是一张新的经验分布。

如果方法运行正常，通常会看到：

1. 当前偏少的记录形态逐渐变多；
2. 当前偏多的记录形态逐渐变少；
3. 高适应度模式先在较大范围内传播；
4. 随着残差变化，旧的高适应度模式可能失去优势；
5. 后期适应度差异和记录变化率下降；
6. 最终查询答案在允许误差内稳定；
7. 由于保留邻近约束和小概率变异，表中可以维持多个模式，而不是只剩一种记录。

不能声称：

- 恢复了真实私有数据；
- 找到了合法记录空间的全局最优；
- 未测量的高阶关系一定正确；
- 所有带噪查询都能同时精确实现。

可以合理声称：

在固定查询目标和合法记录空间下，生成器通过残差驱动的个体适应度、相似记录之间的随机学习和多轮同步演化，使合成表的查询答案逐步接近目标。

19 第一版最小可运行配置

为了防止实现再次跑偏，第一版只保留下面这些内容：

数据：二元或低基数类别属性

查询：1-way 和低阶合取计数

目标：无噪声精确计数

适应度：本文最终公式

参考：全体记录或小型共享参考池

距离：归一化 Hamming 距离

更新：参与概率 + 属性块复制

变异：先关闭，核心跑通后再打开

合法性：简单合法块

接受：整代损失不升

第一版明确不实现：

L0/L1/L2 定向候选

半空间专用跨越

候选-查询二部图

逐候选动态贪心

二候选联合搜索

增量堆和复杂缓存

完整协方差

连续属性复杂处理

20 参考文献与内部材料

[1] Yanbo Zhang, Benedikt Hartl, Hananel Hazan, Michael Levin. *Diffusion Models are Evolutionary Algorithms*. ICLR 2025.

[2] Zhangyanbo. *diffusion-evolution* official code repository. The example loop evaluates population fitness and then generates the next population with `BayesianGenerator`.

[3] 内部材料：《高斯噪声感知的残差驱动合法候选与冲突感知动态选择方法：最终统一实现设计版》，尤其参见第 5、9-10、15 页。

[4] 内部材料：《新方法设计动机说明》，尤其参见第 2-4 页。

21 附录 A: 适应度与平均真实替换收益的推导

在无噪声容忍的加权平方损失下:

$$L(S) = \frac{1}{2} e^\top W e, \quad e = y - q(S).$$

若把第 i 条记录 x_i 替换成 z , 查询答案变化为:

$$d_{i,z} = a(z) - a(x_i).$$

新残差:

$$e' = e - d_{i,z}.$$

真实损失下降:

$$\begin{aligned} L(S) - L(S^{i \rightarrow z}) &= \frac{1}{2} e^\top W e - \frac{1}{2} (e - d_{i,z})^\top W (e - d_{i,z}) \\ &= e^\top W d_{i,z} - \frac{1}{2} d_{i,z}^\top W d_{i,z}. \end{aligned}$$

对被替换记录 i 均匀取平均。记:

$$\bar{a} = \frac{1}{N} \sum_i a(x_i).$$

则:

$$\mathbb{E}_i[d_{i,z}] = a(z) - \bar{a}.$$

并且:

$$\mathbb{E}_i[\|a(z) - a(x_i)\|_W^2] = \|a(z) - \bar{a}\|_W^2 + C_t,$$

其中 C_t 与 z 无关。因此:

$$\mathbb{E}_i[L(S) - L(S^{i \rightarrow z})] = e^\top W (a(z) - \bar{a}) - \frac{1}{2} \|a(z) - \bar{a}\|_W^2 + C'_t.$$

去掉不影响排序的常数, 就得到本文个体适应度。

22 附录 B: 术语对照

文中简单说法	常见专业说法	本文中的含义
参考记录	donor / ancestor	当前记录本轮准备学习的高适应度近邻
相近程度	neighborhood likelihood	两条记录在属性块上的距离权重
选择温度	selection temperature	高适应度记录获得多大概率优势
参与概率	global update rate	一轮有多少记录真正尝试变化
属性块复制	denoising step	当前记录逐步向参考记录靠近
合法变异	mutation	产生当前种群中尚不存在的新状态
整代检查	generation-level guard	防止同步更新过大导致查询误差上升