

表格扩散演化生成器

第七节最终设计：记录参与率下的单块复制与合法变异

讨论定稿版

修订日期：2026-07-31

设计结论

保留记录参与率 ρ_t ；删除逐属性块复制率 η_t ；参与更新后只执行一次原子动作——复制参考记录的一个不同合法块，或变异一个合法块。复制与变异互斥，每条记录每轮最多改变一个合法块。

1. 修订目的与适用范围

本修订稿只重写原方案第七节“一条记录怎样向参考记录靠近一步”。前面的查询残差、个体适应度、参考记录选择，以及后面的整代同步更新和整代安全检查，均保持原有框架不变。

修订的核心目标是减少控制参数和随机层次，同时保留三项必要能力：控制一轮更新范围、沿参考记录方向传播已有模式、通过合法变异发现当前种群中不存在的新状态。

不采用的方案

不直接整行复制参考记录；不先从全表固定抽取若干“修改名额”；不为每条记录计算多个候选动作后贪心选择；不引入额外的动作温度、软预算或参考适应度差参数。

2. 最终核心规则

对于当前记录 x_i 和本轮已抽到的参考记录 z_i^* ，每条记录先以记录参与率 ρ_t 决定是否获得一次更新机会。未参与时保持不变；参与后只在“复制一个参考块”和“变异一个合法块”之间选择一种动作。

$$A_i \in \{\text{保持不变, 复制一个参考块, 变异一个合法块}\}$$

$$P(\text{保持不变})=1-\rho_t$$

$$P(\text{复制一个参考块})=\rho_t(1-\varepsilon)$$

$$P(\text{变异一个合法块})=\rho_t \varepsilon$$

其中， ρ_t 是本轮记录参与率； ε 是参与更新后分配给变异的固定比例。第一版只让 ρ_t 随整代安全检查变化， ε 固定不变。

3. 两个参数分别控制什么

参数	控制对象	普通话解释	第一版处理
ρ_t	更新广度	一轮中大约有多少比例的记录获得一次更新机会	动态步长；整代损失上升时减半
ε	探索比例	参与更新的记录中，有多少用于发现新状态	固定小常数，不单独退火

与原设计相比，属性块复制率 η_t 被删除。参与记录不再对所有不同块逐个抛硬币，而是最多只改变一个最小合法块，因此单条记录的步幅固定、含义清楚。

4. 完整的一步转移过程

1. 输入当前记录 x_i 、参考记录 z_i^* 、记录参与率 ρ_t 、变异占比 ε 、合法属性块定义和随机数生成器。
2. 抽取 $U_i \sim \text{Bernoulli}(\rho_t)$ 。若 $U_i=0$ ，则令 $u_i=x_i$ ，本轮结束。

3. 若 $U_i=1$ ，再抽取 $M_i \sim \text{Bernoulli}(\epsilon)$ 。若 $M_i=0$ ，尝试复制一个参考块；若 $M_i=1$ ，尝试变异一个合法块。
4. 复制与变异互斥；不论选择哪一种动作，每条记录每轮最多改变一个最小合法块。
5. 执行结构合法性约束和最终 is_valid 检查；失败时少量重抽，仍失败则回退到 x_i 。
6. 所有记录独立生成一个下一状态，随后同步组成完整下一代表。

实现上的“一步”

代码可以直接对三种最终动作做一次 categorical 抽样；文档仍保留“先参与、再决定复制或变异”的解释，是为了让 p_t 的控制意义更清楚。两种写法在概率上等价。

5. 复制动作

定义当前记录与参考记录之间可复制的不同合法块集合：

$$D_i = \{g : x_{ig} \neq z^*_{ig}, g \text{ 可修改, 且该块复制动作满足结构约束}\}$$

当抽到复制动作时，从 D_i 中随机选择一个块 g ，将参考记录该块复制到当前记录，其余块保持不变。第一版在 D_i 中均匀抽取，不增加块级收益分数或额外温度参数。

$$u_{ig} = z^*_{ig}, \text{ 且对所有 } h \neq g, \text{ 有 } u_{ih} = x_{ih}$$

如果 D_i 为空，则本轮保持不变，不自动转成变异。这样可以保证 ϵ 的含义稳定，避免“参考记录相同”时实际变异率被被动放大。

6. 变异动作

变异是必要组成部分。只复制当前种群中已有记录的属性块，无法产生当前种群中完全不存在的取值或合法组合。变异负责向新的合法状态开放路径。

7. 随机选择一个可修改的最小合法块 g 。
8. 从该块的合法变异分布 $P_{\text{mut},g}(\cdot | x_i, -g)$ 中抽取新值或新模板。
9. 优先排除当前值，避免抽到原值后形成无效变异。
10. 进行少量重抽；多次失败后取消本次变异并回退到 x_i 。

合法变异分布可来自初始化使用的低阶先验、公开统计、合法模板库，或合法值集合上的均匀分布。第一版应优先保证“能生成合法状态”，不要先追求复杂的条件模型。

7. 最小合法块的定义

这里的“一块”不是必须等于一个字段，而是一次变化所允许的最小合法单位。若多个字段必须共同变化才能合法，应把它们合并为同一属性块。

示例块	可能包含的字段	更新方式
普通类别块	学历	复制或变异一个类别值
数值/分箱块	年龄段	复制分箱或从合法分布抽取
联合模板块	职业代码 + 行业代码	整体复制或整体变异为合法模板
层级编码块	地区代码 + 行政层级	整体保持层级一致
不可修改块	固定标识或外生条件	不进入复制与变异集合

8. 记录参与率与实际变化率

ρ_t 表示记录获得更新机会的概率，不等于最终真正变化的记录比例。实际变化率定义为：

$$c_t = (1/N) \sum_i 1[u_i \neq x_i]$$

通常有 $c_t \leq \rho_t$

参与后仍可能保持不变，原因包括：没有可复制差异块、变异重抽失败、合法性检查失败、或抽到与当前状态等价的结果。因此诊断时必须同时记录参与率和实际变化率。

9. 整代安全检查与步长回退

所有记录同步产生完整下一代表 U_t 后，再计算整代损失。若下一代损失不升，则接受；若损失明显上升，则只缩小记录参与率 ρ_t 后重新生成整代。

若 $E(U_t) \leq E(S_t) + \xi$ ，则接受 U_t

否则令 $\rho_t \leftarrow \rho_t / 2$ ，并重新抽取整代

最多重试若干次；仍无法得到不升的下一代时，本轮保持原表并记录停滞。 ϵ 不随回退单独调整，因为总变异概率 $\rho_t \epsilon$ 会随着 ρ_t 一起下降。

10. 推荐的第一版参数

参数	建议起点	太小的表现	太大的表现
ρ_t	0.01 或 0.02 起步	收敛慢、每轮变化过少	整代过冲、回退频繁
ϵ	固定 0.01；消融可试 0.005/0.01/0.02	新模式发现慢	随机扰动偏多
max_retry	3 到 5	容易放弃可改善轮次	重复计算开销上升

第一版不建议同时为 ρ_t 设计复杂退火曲线。先固定 ρ_t ；仅在整代损失上升时减半。核心行为验证通过后，再比较固定、线性下降或自适应方案。

11. 必须记录的诊断量

- participation_rate: 实际抽到参与更新的记录比例;
- copy_attempt_rate: 尝试复制一个参考块的比例;
- mutation_attempt_rate: 尝试合法变异的比例;
- accepted_change_rate: 最终记录内容真正发生变化的比例;
- empty_copy_set_count: 抽到复制但 D_i 为空的记录数;
- invalid_proposal_count: 合法性失败并回退的次数;
- generation_retry_count: 整代损失上升后的重抽次数;
- rho_used: 该轮最终实际采用的 ρ_t 。

如果 participation_rate 接近 ρ_t , 但 accepted_change_rate 明显更低, 应优先检查参考记录是否过于相同、合法块划分是否过严、变异分布是否经常产生非法值, 而不是立刻提高 ρ_t 。

12. 推荐伪代码

```
def evolve_row_once(x, donor, rho, epsilon, schema, rng):
    # 1. 记录是否参与本轮更新
    if rng.random() >= rho:
        return x, "stay"

    # 2. 复制与变异互斥
    do_mutation = rng.random() < epsilon

    if do_mutation:
        for _ in range(schema.max_local_retry):
            g = schema.sample_mutable_block(rng)
            u = schema.mutate_one_block(x, g, rng)
            if u != x and schema.is_valid(u):
                return u, "mutation"
        return x, "mutation_fallback"

    # 3. 尝试复制参考记录的一个不同合法块
    D = schema.legal_different_blocks(x, donor)
    if not D:
        return x, "copy_empty"

    g = rng.choice(D)
    u = schema.copy_block(x, donor, g)
    if schema.is_valid(u):
        return u, "copy"
    return x, "copy_fallback"

def evolve_generation(S, donors, rho, epsilon, schema, rng):
    proposal = [
        evolve_row_once(x, z, rho, epsilon, schema, rng)[0]
        for x, z in zip(S, donors)
```

```
]
return proposal
```

13. 与原第七节的差异

项目	原设计	最终设计
记录是否参与	Bernoulli(ρ_t)	保留不变
参与后复制多少块	每个不同块以 η_t 独立复制	最多随机复制一个不同合法块
变异	复制过程后再以 μ_t 变异	与复制互斥，参与后以固定 ε 选择变异
单条记录最大步幅	可能同时改变多个块	每轮最多改变一个合法块
主要动态参数	ρ_t 、 η_t 、 μ_t	仅 ρ_t ； ε 固定
整代过冲处理	降低 ρ_t ，必要时降低 η_t	只需降低 ρ_t

14. 可直接替换第七节的定稿表述

第七节核心表述

对当前记录 x_i 和本轮抽到的参考记录 z_i^* ，先以记录参与率 ρ_t 决定该记录是否获得一次更新机会。未参与则保持不变；参与后，以固定概率 ε 执行一次合法块变异，否则随机复制参考记录的一个不同合法块。复制与变异互斥，每条记录每轮最多改变一个最小合法块。若不存在可复制差异块、局部动作不合法或多次重抽失败，则回退到原记录。所有记录同步形成完整下一代表，并通过整代损失检查控制 ρ_t 。

15. 最终结论

最终设计保留了记录参与率，因为它是控制整代更新范围最直接、最容易诊断和回退的参数；删除属性块复制率，因为“参与后只改一个块”已经给出了稳定步长；保留变异，但把它作为参与后的互斥动作，并使用固定小比例 ε 。

最终结构： ρ_t + 固定 ε + 每次最多一个最小合法块

该设计既保持了原方法“每条记录每轮只产生一个下一状态、所有记录同步演化”的基本路线，又显著减少了参数耦合和单条记录的大步跳动。