

表格扩散演化生成器

线性距离版新型参考记录抽样方法设计

与原 “.md” 方法对比、改进说明及参数调节准备

核心变化：保留 “.md”
的纯方向适应度、比例残差和整代保护；根据现有实验结论，将参考记录抽样中的距离代价由 d^2 改为 d ，并继续使用“局部约束系数 λ + 抽样集中度 s ” 的双参数表示。

当前状态	结论
距离形式	已根据实验结论确定采用线性距离代价 d
λ 、 s 数值	尚未开始调参，不给出已选范围或最优值
动态调度	仅保留为后续候选方案，当前不作为已验证结论
依据优先级	temp.md > 两份原始方案 PDF；本修订稿同时吸收用户最新实验结论

版本：线性距离修订稿（参数尚未标定）

摘要与最终结论

推荐的新抽样分数：

$$\ell_{ik}^{(t)} = s_t[(1-\lambda_t)F_t(z_k) - \lambda_t d(x_i, z_k)]$$

其中， λ_t 表示线性距离约束在相对权衡中的占比， s_t 表示整个 softmax 抽样分布的集中程度。距离 d 保持为归一化属性块距离，不再平方。

层次	原 `temp.md` 方法 / 原具体化	线性距离版新方法
适应度	纯方向适应度；不做种群 z-score	完全保留
查询权重	原 PDF 通常归一化为平均值 1	设计稿继续采用固定权重和为 1；仍待独立消融
距离代价	两份 PDF 具体化为 $d^2/(2h^2)$	根据当前实验结论改为线性 d
抽样参数	β 与 h （平方核尺度）	λ 与 s ；或等价 β 与线性距离强度 γ
参数状态	旧文档给出候选调度	尚未开始调参；删除数值范围和“已选参数”表述
保护机制	残差相关更新率 + 整代损失检查	完全保留

本次修订最重要的边界：距离形式已经改变，但参数值尚未标定。因此，不需要把旧 λ 范围换算到新 λ ，也不能保留旧稿中 $\lambda=0.25\rightarrow0.55$ 、 $s=1.5\rightarrow3.0$ 一类候选数值。新的线性距离版本应从固定 λ 、 s 基线重新开始调参。

1. 来源边界与版本关系

编号	来源	本报告采用的内容
S1	temp.md（最高优先级）	比例残差、纯方向适应度、删除 z-score、更新率与整代保护、停止规则
S2	表格扩散演化生成器_完整方案.pdf	查询权重原始设计、属性块距离、单参考记录抽样框架
S3	扩散演化生成器_从零实现与实验计划.pdf	原 β /温度与 h 的实现逻辑、测试和诊断要求
E1	用户最新实验结论	抽样距离代价由 d^2 改为 d ；参数尚未开始调节
N	本文新增设计	权重和为 1、 λ/s 重参数化、线性距离参数映射与后续调参流程

2. 原 `.md` 方法的完整结构

2.1 查询贡献、比例残差与噪声容忍

对第 j 个查询，单条记录 z 的贡献记为 $a_j(z)$ 。当前表 S_t 的查询答案为 $q_j(S_t)$ ，目标为 y_j 。`.md` 将噪声容忍后的计数误差除以记录数 N ：

$$\varepsilon_{j,t} = \text{sign}(y_j - q_j(S_t)) \cdot \max(|y_j - q_j(S_t)| - \kappa\sigma_j, 0) / N$$

这一设计保留误差方向和相对大小，同时把“条数”尺度转换为“比例”尺度。进入 $\kappa\sigma_j$ 容忍区后，该查询不再提供增加或减少的方向。

2.2 纯方向适应度

令 $p_{j,t} = q_j(S_t) / N$ ，则记录形态 z 的适应度为：

$$F_t(z) = \sum_{j=1}^m w_{j,t} [a_j(z) - p_{j,t}]$$

它只回答：这种记录相对于当前平均记录，能否把尚未满足的查询朝正确方向推动。`.md` 删除了原个体适应度中的二次步幅项，把防止过冲的职责交给更新率与整代真实损失检查。

2.3 不再进行种群 z -score

`.md` 明确不再使用当前种群标准差对适应度逐代标准化。原因是标准差通常随残差同步缩小；除以标准差会约掉残差幅度，使算法接近目标时仍保持过强选择压力。允许减去共同均值，但不除以当前种群标准差。

2.4 原 `.md` 的参考记录抽样层

`.md` 在方法层给出一般形式：

$$\Pr_t(z|x) \propto \exp[\beta_t F_t(z)] \times \text{similarity}(x, z)$$

它要求高适应度且相近的记录更容易成为参考，但没有在 `.md` 中强制相近程度必须是平方距离。两份旧 PDF 使用平方距离核只是这一一般形式的一种具体化。

2.5 过冲与稳定性机制

- 适应度只决定演化方向。
- 记录参与率 ρ 、属性块复制率 η 、变异率 μ 决定一轮实际走多远。
- 整代损失检查判断同步提案是否走过头。
- 所有有效残差为 0 时，在抽参考记录之前立即停止。
- 始终保存运行过程中损失最低的完整表。

3. 原平方距离具体化及其局限

3.1 原具体抽样公式

两份旧 PDF 将相近程度具体化为平方距离高斯核：

$$\ell_{ik}^{\text{old}} = \beta_t F_t(z_k) - d(x_i, z_k)^2 / (2h_t^2)$$

等价地，相近程度为 $\exp[-d^2/(2h^2)]$ 。这里 h 是平方核的邻域尺度： h 大时距离影响弱， h 小时抽样更局部。

3.2 平方距离的行为

在 $d \in [0, 1]$ 内， $d^2 \leq d$ 。平方距离对非常近的记录更宽容，但其边际惩罚 $2d$ 随距离增加而增大：距离越远，再增加相同距离带来的额外惩罚越强。




图 1 线性距离 d 与平方距离 d^2 的形状差异。该图仅说明函数形状，不代表任何参数已经完成标定。

3.3 为什么本修订稿不再保留平方距离

根据用户当前实验结论，线性距离版本相较平方距离版本表现更适合当前任务，因此新方法不再追求与原 h 参数的严格等价。这里的“实验验证”仅指距离函数形式已作出选择；由于未提供具体实验数据，本报告不对提升幅度、显著性或适用范围作额外推断。

4. 线性距离版新方法：完整设计

4.1 设计目标

- 1 保留 `.md` 的纯方向适应度、比例残差、停止规则和整代保护。
- 2 将参考记录距离代价由 d^2 改为 d ，使每个额外属性块差异产生近似恒定的对数概率惩罚。
- 3 继续将“适应度-距离相对权衡”与“softmax 集中程度”分开。
- 4 参数值从零开始标定，不继承旧平方距离版本的候选范围。
- 5 动态调度仅作为固定参数基线通过后的候选增强。

4.2 查询权重：固定归一化为和 1

仍可沿用逆方差可信度作为原始权重 $u_j = 1/(\sigma_j^2 + \sigma_{\min}^2)$ ，再固定归一化为：

$$w_j = u_j / \sum_{k=1}^m u_k, \quad \sum_{j=1}^m w_j = 1$$

若没有噪声信息，则可先令 $w_j = 1/m$ 。权重在运行开始前固定，不按每轮活跃查询重新归一化。这一尺度规范仍属于新方法设计，尚需与“权重平均为 1”做独立消融。

4.3 适应度与记录距离

适应度继续采用：

$$F_t(z) = \sum_{j=1}^m w_j \varepsilon_{j,t} [a_j(z) - p_{j,t}]$$

记录距离保持为归一化属性块加权平均：

$$d(x, z) = [\sum_g \omega_g \delta_g(x_g, z_g)] / \sum_g \omega_g, 0 \leq d(x, z) \leq 1$$

本次修改发生在抽样代价：直接使用 d ，而不是 d^2 。距离本身的定义、自反性、对称性和归一化范围不变。

4.4 新抽样分数与概率

$$\ell_{ik}^{(t)} = s_t[(1-\lambda_t)F_t(z_k) - \lambda_t d(x_i, z_k)]$$
$$\Pr_t(J_i=k)=\exp(\ell_{ik})/\sum_{l \in D_t} \exp(\ell_{il})$$

符号	名称	作用
$\lambda_t \in [0,1]$	局部约束系数	决定线性距离项在相对权衡中的占比；越大越偏向近邻
$1-\lambda_t$	适应度占比	越大越重视能够推动残差的参考记录
$s_t > 0$	抽样集中度	统一放大或压缩 logits；越大 softmax 越集中
d	线性距离代价	每增加相同距离，产生相同的 logit 惩罚
F_t	纯方向适应度	只提供演化方向，不承担过冲保护

5. 线性距离设计的物理含义

5.1 恒定边际距离惩罚

新距离项为 $-s_t \lambda_t d$ 。对距离 d 的导数是常数：

$$\partial \ell_{ik} / \partial d = -s_t \lambda_t$$

因此，距离每增加相同幅度，logit 都减少相同的量。若距离是 G 个可修改属性块上的归一化 Hamming 距离，每多一个不同块， $\Delta d=1/G$ ，对数抽样权重固定减少 $s \lambda / G$ 。

5.2 与表格属性块距离的加性解释

线性距离与“不同属性块的加权数量”保持直接对应：各块差异先在线性距离中相加，再统一进入抽样分数。平方距离则会让多个块差异之间出现整体非线性放大。当前实验结论支持线性形式，说明对现有属性块空间而言，加性的距离惩罚更合适。

5.3 极限行为

参数状态	抽样行为
$\lambda=0$	只按适应度选择，不施加距离约束；存在全局复制与多样性下降风险
$\lambda=1$	只按距离选择，忽略查询残差方向；不能保证改善查询目标
$s \rightarrow 0$	概率接近均匀，探索强但选择信号弱
s 较大	概率集中于少数综合高分参考记录；利用强但可能坍缩
$F_t \rightarrow 0$	接近目标时适应度方向自然减弱；若全部有效残差为 0 则直接停止

5.4 当前能够与不能够得出的结论

能够确认	尚不能确认
抽样距离函数应采用一次距离 d	λ 、 s 的最佳值或稳定范围
旧平方核映射不再适用	动态调度一定优于固定参数
必须重新建立线性距离基线	权重和为 1 一定优于权重平均为 1
测试需加入线性等距 <code>logit</code> 性质	性能提升幅度和跨数据集泛化结论

6. 参数表示与新旧映射

6.1 线性距离的自然双强度形式

线性距离版可以先写成两个直接强度参数：

$$\ell_{ik} = \beta_t F_t(z_k) - \gamma_t d(x_i, z_k)$$

其中 β_t 是适应度选择强度， γ_t 是线性距离惩罚强度。将其重参数化为 λ 、 s ：

$$\begin{aligned} \beta_t &= s_t(1-\lambda_t), \gamma_t = s_t \lambda_t \\ s_t &= \beta_t + \gamma_t, \lambda_t = \gamma_t / (\beta_t + \gamma_t) \end{aligned}$$

这组映射对所有参考记录严格成立。 λ 决定“适应度与线性距离的相对占比”， s 决定“整个抽样分布有多集中”。

6.2 若仍希望保留邻域尺度记号 h

可定义 $\gamma_t = 1/h_t$ ，得到：

$$\ell_{ik} = \beta_t F_t(z_k) - d(x_i, z_k)/h_t$$

此时 h 大表示距离惩罚弱， h 小表示局部约束强；但它不再是高斯核标准差，也不能再使用 $1/(2h^2)$ 的旧映射。

6.3 不需要做旧参数换算

由于 λ 、 s 尚未开始调节，不存在需要保留的旧最优参数或旧稳定区间。因此，本次修订不进行“平方距离 $\lambda \rightarrow$ 线性距离 λ ”的数值换算。正确做法是直接以线性距离公式建立固定参数基线，再从头调节 λ 与 s 。

旧稿内容	线性距离修订
$d^2/(2h^2)$	γd ，或 d/h
$1/(2h^2) = s\lambda$	$\gamma = s\lambda$ ；若 $\gamma = 1/h$ ，则 $1/h = s\lambda$
$s = \beta + 1/(2h^2)$	$s = \beta + \gamma$
$\lambda = [1/(2h^2)] / [\beta + 1/(2h^2)]$	$\lambda = \gamma / (\beta + \gamma)$
高斯邻域核	指数衰减型线性距离权重

7. 需要同步修改的内容

7.1 公式和术语

原内容	修改后
距离代价 d^2	线性距离代价 d
平方距离 / 高斯型邻域	线性惩罚 / 指数衰减型邻域
$-d^2/(2h^2)$	$-\gamma d$, 或 $-d/h$
h 是高斯邻域尺度	h 是线性指数衰减尺度 (仅在采用 $-d/h$ 时)
距离平方与原 h 严格对应	删除该表述, 改用 β/γ 与 λ/s 的新对应

7.2 参数相关内容

- 删除旧稿中所有 λ 、 s 的具体候选数值、起止值和变化曲线。
- 删除“ λ 与 s 已确定从某数值增加到某数值”的表述。
- 保留参数定义域 $\lambda \in [0,1]$ 、 $s>0$, 但不将边界值视为建议值。
- 固定参数版是第一基线; 动态版仅作为后续待验证方案。
- 调参时不沿用平方距离版本的参数范围。

7.3 测试和诊断

- 适应度相同、距离更近的参考记录应更常被选择。
- 距离相同、适应度更高的参考记录应更常被选择。
- 当候选距离等间隔时, 线性距离项产生等间隔 logits 。
- 理论 softmax 概率应与大量经验抽样频率一致。
- λ 增大时, 平均 donor 距离应总体下降。
- s 增大时, 归一化熵和有效样本量 ESS 应总体下降。
- 始终监控整代拒绝率、多样性和不同随机种子方差。

线性等距测试: 若 $d_1=a$ 、 $d_2=a+\Delta$ 、 $d_3=a+2\Delta$ 且适应度相同, 则应满足 $\frac{1}{1-\frac{1}{2}} = \frac{2}{2-\frac{1}{3}} = \frac{3}{3-s\lambda\Delta}$ 。

8. 原方法与线性距离新方法的优缺点

8.1 原 β + 平方距离具体化

优点	缺点
β 与 h 各有传统解释；平方核光滑；与旧 PDF 完全一致	β 与 h 同时影响权衡和集中度；平方距离对块差异形成非线性整体惩罚
h 具有高斯尺度解释	实验已表明平方距离不适合当前配置，因此继续保留会违背现有证据

8.2 线性距离 λ/s 新方法

优点	缺点与风险
λ 管相对权衡， s 管集中度，参数职责更清晰	λ 与 s 的实际系数 $s(1-\lambda)$ 、 $s\lambda$ 仍有关联，并非完全独立
线性距离具有每个额外块固定惩罚的直接解释	旧 h 的高斯尺度解释和平方核严格等价关系消失
与当前实验选择一致	参数尚未标定，不能声称调参更容易已经被实证确认
可直接组织为“局部约束 $\times$ 抽样集中度”的二维实验	权重和为 1、动态调度仍是待消融的新假设

8.3 综合对比

维度	平方距离 β/h	线性距离 λ/s
距离形式	d^2	d
边际距离惩罚	随 d 增大	恒定
块差异解释	整体非线性	近似加性
参数坐标	β/h	λ/s 或 β/γ
当前实验结论	已被淘汰	采用，但参数待调

9. 参数调节状态与后续计划

截至本修订稿，距离函数形式已经确定为线性，但 λ 、 s 尚未开始调节。以下内容只规定调参顺序和判据，不给出任何候选数值或“推荐范围”。

9.1 第一阶段：固定参数基线

- 1 固定记录参与率 ρ 、块复制率 η ，并暂时关闭或固定很小的变异率 μ 。
- 2 先固定 s ，在 λ 从低到高的多个水平上比较抽样局部性与查询损失。
- 3 选出稳定的 λ 区域后，再在该区域内从低到高调节 s 。
- 4 每个组合使用多个随机种子，不依据单次最好结果作结论。
- 5 寻找稳定区域，而不是寻找一个孤立的最优点。

9.2 第二阶段：移动幅度参数

在 λ 、 s 的固定基线确定后，再调节记录参与率 ρ 与块复制率 η 。它们决定一轮有多少记录发生变化以及每条记录移动多远，不能与抽样参数同时大范围搜索。

9.3 第三阶段：变异与动态调度

最后再调 μ ，并比较固定 λ/s 与动态 λ_t/s_t 。动态版本是否采用、参数是同向还是部分固定，必须由固定基线和消融结果决定，不在当前文档中预设。

9.4 必须报告的指标

类别	指标	主要判断
查询拟合	最终损失、最低损失、损失曲线面积、进入容忍区轮数	是否有效、是否快速
抽样行为	平均 donor 距离、距离分位数、归一化熵、ESS	λ 与 s 是否起到预期作用
稳定性	整代拒绝率、过冲次数、随机种子方差	参数是否过强或脆弱
多样性	唯一记录形态数、属性边际熵、参考记录选择集中度	是否发生模式坍缩
实际系数	$c_F=s(1-\lambda)$ 、 $c_D=s\lambda$ 、适应度跨度	识别参数耦合与尺度问题

10. 推荐的最终方法规范

10.1 核心公式

$$w_j = u_j / \sum u_k, \sum w_j = 1$$

$$\varepsilon_{j,t} = \text{sign}(y_j - q_j(S_t)) \cdot \max(|y_j - q_j(S_t)| - \kappa \sigma_j, 0) / N$$

$$F_t(z) = \sum w_j \varepsilon_{j,t} [a_j(z) - p_{j,t}]$$

$$d(x, z) = \sum \omega_g \delta_g(x_g, z_g) / \sum \omega_g$$

$$\ell_{ik}^{(t)} = s_t [(1 - \lambda_t) F_t(z_k) - \lambda_t d(x_i, z_k)]$$

$$\Pr_t(J_i = k) = \exp(\ell_{ik}) / \sum \exp(\ell_{il})$$

10.2 不可破坏的边界规则

- 1 查询权重在运行开始前固定，不按每轮活跃查询重新归一化。
- 2 适应度不做当前种群 z-score、min-max 或范数归一化。
- 3 抽样中使用线性距离 d，不再出现 d²。
- 4 每条当前记录每轮只抽一个参考记录。
- 5 所有有效残差为 0 时，在抽样前立即停止。
- 6 已满足查询不再提供方向，但仍参加整代损失或保护区检查。
- 7 过冲控制由残差相关更新率和整代保护承担，不重新加入个体适应度。
- 8 始终保存运行过程中损失最低的完整表。
- 9 参数尚未标定前，不在方法文档中写入具体候选范围或最佳值。

10.3 当前最稳妥的结论表述

本方法在 `\.md`

纯方向适应度框架下，将参考记录抽样中的相近程度具体化为归一化属性块距离的线性惩罚，并采用 λ/s 参数化分别描述局部约束占比与抽样集中程度。现有实验结论支持去除平方距离项，但 λ 、s 及其动态调度尚未标定，后续需要通过固定参数基线、多随机种子实验和分层消融确定稳定区域。

附录 A：相对上一版 PDF 的修订清单

位置/主题	上一版	本修订版
封面核心变化	保留平方距离核	改为线性距离代价；参数尚未标定
摘要公式	$-\lambda d^2$	$-\lambda d$
距离解释	高斯型邻域、近邻宽容	恒定边际惩罚、属性块差异近似加性
新旧映射	$1/(2h^2)=s\lambda$	$\gamma=s\lambda$ ；可选 $\gamma=1/h$
参数范围	包含 λ 、 s 候选起止值	全部删除；尚未开始调参
动态曲线	给出同方向线性变化图	删除；动态调度降为后续候选
测试	平方距离核相关测试	新增等距离增量对应等 logit 惩罚测试
结论措辞	与 β/h 严格等价重参数化	仅与 β/γ 线性形式严格等价；不再与平方核等价

附录 B：建议实验顺序

阶段	方法	目的
A	线性距离 λ/s 固定； ρ 、 η 固定； μ 关闭或固定	建立新的抽样基线
B	先调 λ ，再调 s	分离局部性与集中度作用
C	固定 λ/s 后调 ρ 、 η	确定一轮移动幅度
D	最后调 μ	验证缺失状态探索能力
E	固定参数 vs 动态参数；权重平均 1 vs 权重和 1	识别新增设计的独立贡献

修订说明：本 PDF 依据用户上传的上一版方法设计稿更新。距离形式采用用户最新实验结论；没有实验数据支持的具体参数值、性能幅度和最优性结论均未写入。