

适应度-相似度联合抽样方法

最终简化版：稳健归一化 + 加权几何平均 + 动态尖锐度

核心结论

适应度与相似度用加权几何平均形成“软 AND”综合分数；前期和后期只通过一个动态尖锐度参数 α_t 控制概率分布由平到尖。方法不再设置额外探索率，也不分别调度适应度和距离强度。

适用场景

从候选集合中，为当前记录按概率抽取参考对象；候选适应度越大越好，归一化距离 $d \in [0,1]$ 越小越好。

版本：Final-1.0

1. 设计目标与最终取舍

抽样函数只包含两个实质信息：候选适应度 F_k 和当前记录到候选的距离 d_{ik} 。设计需要同时满足以下目标：

- 适应度越高，候选越优；距离越小，候选越匹配。
- 适应度与相似度不能完全相互补偿，综合评分应体现“二者都较好”。
- 不能直接使用原始适应度尺度，也不能因最小值归一化为 0 而彻底抹去距离作用。
- 前期抽样应较分散，后期应更集中，但不再额外引入独立探索率。
- 参数职责应清楚：一个参数控制适应度/相似度倾向，一个参数控制整体尖锐程度。

最终取舍

采用加权几何平均而不是加法、直接乘积或纯排名；采用动态幂指数 α_t 控制尖锐度；采用固定底值 δ 保留非零概率；采用截尾归一化降低离群适应度的影响。

2. 变量与符号

符号	含义
F_k	第 k 个候选的适应度，越大越好
d_{ik}	当前记录 i 与候选 k 的归一化距离，范围 $[0,1]$ ，越小越好
$\hat{F}_k$	稳健归一化后的适应度，范围 $[0,1]$
f_k	加入底值后的适应度偏好，范围 $[\delta,1]$
s_{ik}	加入底值后的相似度偏好，范围 $[\delta,1]$
λ	适应度与相似度的固定相对权重，范围 $[0,1]$
α_t	第 t 轮的动态尖锐度，随迭代增加
K	候选数量

3. 最终完整方法

3.1 稳健归一化适应度

对当前候选集合的适应度先进行分位数截尾，再进行 min-max 归一化。设低、高分位点分别为 q_L 和 q_H ：

$$q_L = Q_{0.05}(F), \quad q_H = Q_{0.95}(F)$$

$$F_k^c = \text{clip}(F_k, q_L, q_H)$$

$$\hat{F}_k = (F_k^c - q_L) / (q_H - q_L + \epsilon)$$

截尾的作用是限制单个极端适应度对整体尺度的支配，避免其余候选被压缩到接近 0。若 $q_H - q_L$ 小于数值阈值，说明当前候选适应度几乎相同，统一令 $\hat{F}_k = 1$ ，此时由相似度区分候选。

3.2 构造正值适应度与相似度

$$f_k = \delta + (1 - \delta) \hat{F}_k$$

$$s_{ik} = \delta + (1 - \delta) (1 - d_{ik})$$

因此 f_k 与 s_{ik} 都位于 $[\delta, 1]$ 。底值 δ 避免最差适应度或最大距离直接产生零权重，使任一候选不会仅因归一化边界而被彻底排除。

3.3 用加权几何平均形成综合分数

$$A_{ik} = f_k^\lambda \cdot s_{ik}^{(1-\lambda)}$$

默认 $\lambda = 0.5$ 时， $A_{ik} = \sqrt{f_k s_{ik}}$

几何平均是一种“软 AND”：只有适应度和相似度同时较好，综合分数才高。它比加法更少补偿，又比直接乘积保持更直观的数值尺度。

3.4 动态尖锐度

$$\alpha_t = \alpha_{\min} + (\alpha_{\max} - \alpha_{\min}) \cdot t / (T-1)$$

α_t 只控制分布的整体尖锐程度，不改变适应度和相似度的相对权重。第一版采用线性增加，避免引入额外调度形状。

3.5 最终抽样概率

$$P_t(k|i) = A_{ik}^{\alpha_t} / \sum_j A_{ij}^{\alpha_t}$$

等价的数值稳定实现为：

$$\text{logit_ik} = \alpha_t [\lambda \log(f_k) + (1-\lambda) \log(s_ik)]$$

$$P_t(k|i) = \text{softmax_k}(\text{logit_ik})$$

4. 两个核心参数的职责

参数	是否变化	职责	默认值	解释
λ	固定	控制更看重适应度还是相似度	0.5	$\lambda > 0.5$ 更重适应度； $\lambda < 0.5$ 更重相似度
α_t	动态	控制抽样概率由平到尖	0.5 $\rightarrow$ 4.0	前期压平差异，后期放大差异
δ	固定常数	避免零权重与硬排除	0.05	一般不作为主调参项

4.1 λ ：倾向参数

λ 不随迭代改变，它表达数据集或任务层面的固定偏好：

- $\lambda = 0.5$ ：适应度和相似度同等重要；
- $\lambda = 0.7$ ：更重视候选适应度；
- $\lambda = 0.3$ ：更重视局部相似性。

第一版固定 $\lambda = 0.5$ 。只有跨数据集实验明确显示偏向不足时，再在 {0.3, 0.5, 0.7} 中选择。

4.2 α_t ：尖锐度参数

对于两个综合分数 A_1 和 A_2 ，其概率权重比为：

$$P_1/P_2 = (A_1/A_2)^{(\alpha_t)}$$

α_t	分布效果	运行含义
0.5	压平	候选概率较接近，前期更分散
1.0	原始比例	按综合分数直接归一化
2.0	中等放大	逐步偏向优质近邻
4.0	较强放大	后期集中开发，但不过度极端

“探索” 的准确含义

本方法不单独设置随机探索率。前期 $\alpha_t < 1$ 会压平综合分数差异，使更多候选保留可观概率，这就是前期探索；后期 $\alpha_t > 1$ 放大差异，转向开发。 δ 只负责避免边界归零，不负责调节探索强度。

5. 为什么选择几何平均

组合方式	逻辑	评价
加权相加	允许明显补偿	适应度很高可抵消距离很差，不符合“二者都要较好”
直接乘积	严格 AND	容易把 [0,1] 分数整体压小，尺度不直观
取最小值	完全由短板决定	另一项改善几乎不起作用，过于僵硬
加权几何平均	软 AND	限制补偿、保留连续性、尺度较直观，适合作为最终方案

示例：适应度偏好 $f=0.9$ ，相似度偏好 $s=0.1$ ，等权 $\lambda=0.5$ 。

方法	综合分数	特点
算术平均	0.50	补偿明显
直接乘积	0.09	过度压缩
几何平均	0.30	明显惩罚短板，但不直接压至极低

6. 对此前问题的逐项解决

问题	最终解决方式
适应度 min-max 对离群值敏感	先做 5%-95% 截尾，再归一化
纯排名丢失相邻适应度真实差距	使用归一化后的连续适应度，而非纯排名
最差适应度归一化为 0，距离被抹掉	加入底值 δ ，使 $f_k \geq \delta$
最大距离导致相似度为 0，候选被硬排除	加入底值 δ ，使 $s_{ik} \geq \delta$
加法导致适应度与相似度互相补偿	使用加权几何平均形成软 AND
直接乘积使分数整体偏小	几何平均恢复至与输入接近的尺度

问题	最终解决方式
单一 α 不能控制 F 与 d 的相对权重	用固定 λ 控制相对权重, α 只控制尖锐度
前期需要探索、后期需要开发	α_t 从 0.5 线性增加到 4.0
额外探索率增加参数和功能重复	删除探索率, 前期压平由 α_t 完成
所有候选分数接近时担心放大噪声	采用适中的 $\alpha_{\max}=4$; 若 A 比值接近 1, 幂变换后仍接近 1

7. 运行流程

1. 计算所有候选的适应度 F_k 。
2. 用当前候选集合的 5% 和 95% 分位点截尾, 并归一化得到 $\hat{F}_k$ 。
3. 计算当前记录 i 到每个候选 k 的归一化距离 d_{ik} 。
4. 构造 f_k 和 s_{ik} , 确保二者均位于 $[\delta, 1]$ 。
5. 用加权几何平均得到 A_{ik} 。
6. 根据当前迭代进度计算 α_t 。
7. 使用 log-space 公式和 softmax 得到 $P_t(k|i)$ 。
8. 按 $P_t(\cdot|i)$ 抽取参考候选。

7.1 推荐伪代码

```

q_low = quantile(F, 0.05)
q_high = quantile(F, 0.95)
if q_high - q_low < eps:
    F_norm = ones_like(F)
else:
    F_clip = clip(F, q_low, q_high)
    F_norm = (F_clip - q_low) / (q_high - q_low)

f = delta + (1 - delta) * F_norm
s = delta + (1 - delta) * (1 - distance)

progress = t / max(T - 1, 1)
alpha = alpha_min + (alpha_max - alpha_min) * progress

logits = alpha * (lambda_ * log(f)[None, :] +
                 (1 - lambda_) * log(s))
probs = softmax(logits, axis=-1)

```

8. 边界情况与实现细节

情况	处理
所有适应度相同	令 $\hat{f}_k=1$ ，抽样主要由相似度决定
所有距离相同	s_{ik} 相同，抽样主要由适应度决定
d_{ik} 超出 $[0,1]$ 的浮点误差	计算前 clip 到 $[0,1]$
候选抽到自身	若算法不需要 self-loop，应显式 mask；若允许，应记录自抽样率
小候选集分位数不稳定	K 很小时可退化为直接 min-max；实现中设置候选数阈值
数值下溢	使用 log-space logits，不直接计算极小幂值

8.1 关于“逃逸通道”

由于 $f_k, s_{ik} \geq \delta > 0$ ，所有未被显式 mask 的候选都有正概率，不会因 $d=1$ 或适应度最差而被公式直接置零。但正概率不等于实际抽样概率足够大，因此需要用诊断指标判断是否出现有效坍缩。

9. 推荐默认值与调参顺序

项目	默认值	作用
δ	0.05	固定底值，一般不调
λ	0.50	先固定；跨数据集仅测试 0.3/0.5/0.7
$\alpha_{\min}$	0.50	前期压平强度
$\alpha_{\max}$	4.00	后期尖锐度；先不超过 4
截尾分位数	5% / 95%	抑制离群适应度
ϵ	1e-8	数值稳定常数

调参顺序必须保持简单：

9. 第一步：固定 $\lambda=0.5$ ，只验证 α_t 从 0.5 到 4 的调度是否形成由平到尖的概率变化。
10. 第二步：若后期持续抽取远距离高适应度候选，将 λ 调低至 0.3；若过度局部化，将 λ 调高至 0.7。
11. 第三步：只有概率仍过平或过尖时，再调整 $\alpha_{\max}$ ，不同时调整 λ 和 $\alpha_{\max}$ 。

10. 验证方案

除了最优 loss 和接受率，还需要监控抽样分布与多样性，才能判断尖锐度是否合理。

指标	目的
抽样熵	判断概率分布是否按预期从平到尖
最大候选概率	识别是否过早集中到单个候选
平均抽样距离	观察局部化程度
唯一记录数 / 重复率	识别多样性坍缩
自抽样率	判断是否出现大量无效 self-loop
最优 loss 与下降速度	评价最终性能和收敛效率
接受率	辅助判断提案质量，不单独作为优劣依据

10.1 最小实验矩阵

实验	配置
基线	原 linear 模式
最终方案	$\lambda=0.5$, $\alpha:0.5\rightarrow4$, $\delta=0.05$
倾向检查	$\lambda=0.3 / 0.7$, 其余不变
尖锐度检查	$\alpha_{\max}=2 / 4 / 6$, λ 固定

建议至少在多个数据集和多个随机种子上进行等预算比较。单一数据集上的优势只能说明该配置在该数据集有效，不能直接证明普适性。

11. 方法边界

- 该方法并非数学意义上的完全解耦。最终概率仍由适应度和相似度共同决定，但 λ 与 α_t 的职责被明确区分。
- 截尾会限制极端高适应度候选的优势，这是稳健性与极值敏感性之间的主动取舍。
- δ 保证正概率，但不能保证远候选具有足够大的实际抽样频率；仍需通过抽样熵和多样性指标验证。
- 线性 α 调度是第一版最简选择。只有实验显示前期或后期转换时机明显不合适，才考虑非线性调度。

12. 最终公式汇总

$$\hat{f}_k = [\text{clip}(F_k, Q_{0.05}, Q_{0.95}) - Q_{0.05}] / [Q_{0.95} - Q_{0.05} + \epsilon]$$

$$f_k = \delta + (1 - \delta) \hat{f}_k, \quad s_{ik} = \delta + (1 - \delta)(1 - d_{ik})$$

$$A_{ik} = f_k^\lambda s_{ik}^{(1-\lambda)}$$

$$\alpha_t = \alpha_{\min} + (\alpha_{\max} - \alpha_{\min})t/(T-1)$$

$$P_t(k|i) = A_{ik}^{\alpha_t} / \sum_j A_{ij}^{\alpha_t}$$

一句话概括

先把适应度和相似度稳健地统一到正值区间，用加权几何平均要求二者共同较好，再用一个随迭代增加的 α_t 将抽样分布从前期平缓逐步变为后期尖锐。