
title: 表格扩散演化项目当前进度总结 date: 2026年7月21日 author: table-diffusion
项目组 geometry: margin=2.5cm mainfont: "Noto Sans CJK SC" monofont:
"Noto Sans Mono CJK SC" documentclass: article

项目概览

本项目实现了一个基于扩散演化算法的差分隐私表格合成生成器。当前已完成核心闭环：从随机初始表出发，通过逐代演化逼近查询目标，能将损失从初始 28932 降低至 6102（降幅约 79%）。

一、数据

1.1 源数据

- 文件: `data/test_300x10.csv`
- 规模: 300 条记录 × 10 个属性
- 属性:
 - 1 个数值型 : age (年龄 , 18-100)
 - 9 个类别型 : education、 employment、 income、 marital、 children、 housing、 vehicle、 health、 region
- 用途: 仅用于离线生成 **DP** 查询目标 (铁律 6 : 运行期演化过程不读取源数据)
- **Schema**: `configs/schema.yaml` (公开信息 : 合法取值域 , 不含实际分布)

1.2 合成数据

- 初始化: `generator.py` 的 `init_synthetic_table` , 从 schema 合法域纯随机抽样
 - 记录数: 300 (与源数据一致)
 - 演化后: 最优表 `best_S` 自动保存至 `outputs/<时间>/best_synthetic.csv`
-

二、查询工作负载

2.1 查询定义

- 文件: `configs/measured_50query.json`
- 数量: 50 个查询
- 类型:
 - Single : 单属性查询 (如 " $25 \leq \text{age} \leq 34$ ")
 - Conjunction : 多属性交集查询 (如 " $\text{age} \geq 50$ AND $\text{education}=\text{bachelor}$ ")
- 每个查询包含:
 - conditions : 查询条件 (attribute、operator、value/lower/upper)
 - result : 真实计数 (从源数据评价得到 , 作为演化目标)
 - id、expression、type : 辅助信息

2.2 查询评价

- 实现: `queries.py` 的 `evaluate_table`
 - 功能: 给定一张表 , 返回 50 个查询的计数向量
 - 支持操作符: `==`、`!=`、`>=`、`<=`、`between`、`in`
-

三、模型设计

3.1 核心演化循环（一轮 = 一代）

1. **evaluate_table** → 当前答案 q
2. **compute_residual** → 残差 ε （比例残差，用于适应度）
3. 终止检查: 残差全 0 → 提前停止
4. **compute_fitness** → 适应度 F （纯方向项 $e^T W (a - \bar{a})$ ，无二次项）
5. **pairwise_block_distance** → 距离矩阵（归一化 Hamming 距离）
6. **compute_sampling_probs + sample_donors** → 每条记录抽一个参考记录 (donor)
7. $\text{logit} = \beta \cdot F - d^2 / (2h^2)$ ，按行 softmax
8. **evolve_step** → 生成提案表 proposal
9. 记录参与: Bernoulli(ρ)
10. 块复制概率: η
11. 变异概率: μ （从 schema 合法值均匀抽样）
12. 整代安全检查: $\text{loss}(\text{proposal}) \leq \text{loss}(S) + \text{tol}$ → 接受，否则保持原表
13. 更新 **best_S**（保留历史最优）

3.2 损失函数

$$E(S) = \frac{1}{2} \sum_{j=1}^m w_j [\max(|y_j - q_j| - \kappa \sigma_j, 0)]^2$$

无噪声阶段简化（当前）: $\kappa=0$ 、 $w=1$

$$E(S) = \frac{1}{2} \sum_{j=1}^m (y_j - q_j)^2$$

- 使用计数残差（非比例残差）
- 越小越好， $E=0$ 表示所有查询完全达标

3.3 适应度函数

$$F(z) = e^T W (a(z) - \bar{a})$$

- 只保留方向项（依据 temp.md），删除二次步幅项

- **W** 为对角矩阵: $w_j = 1/\max(|\epsilon_j|, \epsilon_{\min})$, 其中 $\epsilon_{\min}=0.001$
- 防过冲: 交给整代安全检查和更新率控制

3.4 距离度量

归一化 **Hamming** 距离:

- age 块: 数值差除以 67 (归一化到 [0,1])
 - 9 个类别块: 相同记 0、不同记 1
 - 最终距离: 10 个块等权平均, 尺度为 [0, 1]
-

四、参数设置

4.1 当前参数（固定值，未衰减）

参数类型	参数	当前值	来源
抽样	β （选择强度）	1.0	占位值
	h （邻域尺度）	0.8	文档 10.2 起点（建议 0.8→0.15）
更新	ρ （记录参与率）	0.1	文档 10.3 建议区间上界
	η （块复制率）	0.5	文档 10.3 建议区间中值
	μ （变异率）	0.01	文档 10.3 建议区间中值
运行	T （最大轮数）	100	文档 10.4 玩具实验范围
	seed（随机种子）	0	可复现
	tol（整代容差）	1e-9	数值稳定性

4.2 参数解释

抽样参数（用于 **sampling.py**）

- β : 控制多看重适应度。 β 越大，高适应度候选优势越明显
- h : 控制邻域范围。 h 越小，越偏向近邻； h 越大，距离影响越弱

更新参数（用于 **update.py**）

- ρ : 一轮中约多少比例的记录参与更新
- η : 参与记录遇到不同的块，以此概率复制参考记录
- μ : 参与记录以此概率变异一个块

4.3 未用参数（接口已预留）

- κ/σ （噪声容忍）：接口存在，当前无噪声阶段 = 0/None，留给 DP 阶段

- **M/top_fraction** (参考池): 大规模阶段才需要 (建议 $M=512$) , 当前玩具阶段全对全
 - **patience/max_retry**: 早停与重试机制, 当前未实现
-

五、实验结果

5.1 当前最好成绩

配置: seed=0、100 轮、固定参数 ($\beta=1/h=0.8/\rho=0.1/\eta=0.5/\mu=0.01$)

指标	数值
初始 loss	28932.0
最优 loss	6102.0
降幅	约 79%
实际轮数	100 (未提前停止)
接受率	60% (60/100 轮提案被接受)

5.2 结果解读

- 方向正确: loss 单调下降，整代检查保证每轮不恶化
 - 还有改善空间: loss 从 28932 降到 6102，距离完全达标 (loss=0) 尚有距离
 - 步幅合理: 60% 接受率说明参数设置适中 (不过于激进也过于保守)
-

六、代码结构

6.1 已实现模块

模块	文件	核心函数	测试数	职责
Schema	schema.py	load_schema	5	属性结构、合法域
查询评价	queries.py	evaluate_table	10	评价表、查询验证
残差/ Loss	objective.py	compute_residual, compute_loss	20	目标衡量
适应度	fitness.py	compute_fitness	9	个体适应度 (方向项)
距离	distance.py	pairwise_block_distance	10	归一化 Hamming 距离
抽样	sampling.py	compute_sampling_probs, sample_donors	23	donor 抽样
更新	update.py	evolve_step	15	向参考记录 靠近一步
初始化	generator.py	init_synthetic_table	12	随机生成起 点 S0
主循环	evolution.py	run_evolution	12	完整演化流 程
落盘	io.py	save_run	9	结果保存
总计			125	

入口脚本: `scripts/run.py` (一键跑演化+落盘, 参数写在脚本顶部)

测试覆盖: 128 passed (125 个模块测试 + 3 个集成测试)

6.2 运行方式

```
# 一键运行 (默认参数)
conda run -p ./conda python scripts/run.py

# 结果自动保存到
outputs/YYYY-MM-DD_HHMM_N/
├─ best_synthetic.csv      # 最优合成表
└─ diagnostics.json       # 全部诊断信息
```

调参: 直接修改 `scripts/run.py` 顶部常量区的参数值

七、已确定的设计决策

1. 适应度采用纯方向项 (temp.md 方案) : 不用二次步幅项, 防过冲交给整代检查
 2. 抽样分数不标准化适应度 (抽样分数 PDF) : 用 $\beta \cdot F$ 而非 $\beta \cdot (F/\text{std})$
 3. 整代检查失败时保持原表 (第一版) : 不重试、不缩小步幅, best_S 保底
 4. 参数使用固定值 (第一版) : 不随轮次衰减, 调度留给后续版本
 5. 只接收 **target** 不接收源数据 (铁律 6) : 运行期完全不访问私有源表
 6. 结果不进 **git** (outputs/ 在 .gitignore) : 与 data/ 同类, 避免仓库膨胀
-

八、当前未完成（候选增强方向）

按预期收益排序：

1. 参数线性衰减调度
 2. $h/\rho/\eta/\mu$ 从大到小（前期探索、后期精修）
 3. β 方向待定（文档有分歧：固定 vs 递增）
 4. 实现简单（线性插值）、收益明确
 5. 整代检查重试机制
 6. 失败时缩小 ρ 重试（max_retry 3-5 次）
 7. 能抢救更多轮次，提高收敛速度
 8. 终止条件增强
 9. patience：连续多轮不改善就停（建议 10-30 轮）
 10. min_change_rate：记录变化率低于阈值视为稳定
 11. 诊断与可视化
 12. loss 曲线、适应度分布、donor 距离统计
 13. 帮助理解演化过程、指导调参
 14. **DP** 噪声阶段
 15. 启用 κ/σ 参数（噪声容忍）
 16. 真实 DP 查询场景
 17. 大规模扩展
 18. 共享参考池（ $M=512$ ）
 19. 支持 50000 条记录
-

九、技术要点补充

9.1 复现性保证

- 所有随机操作（初始化、抽样、变异）均使用显式传入的 `np.random.Generator`
- 固定 seed 能完整复现 best_S 和 loss 轨迹（铁律 5）
- 测试验证了相同 seed → 相同结果

9.2 职责分离

- 主循环只算不写（evolution.py）：返回结果，不操作文件系统
- 落盘独立函数（io.py）：保存逻辑与演化逻辑分离
- 参数配置在脚本顶部（run.py）：调参不用改主循环代码

9.3 性能与规模

- 当前性能: 300×10×100 轮约 5 秒
- 瓶颈: 距离矩阵计算（300×300 配对），玩具规模无压力
- 扩展路径: 真实规模（50000×10）需启用共享参考池（M=512）

9.4 测试覆盖

- 每个模块有独立测试（最少 5 个、最多 23 个）
- 边界情况: $\beta=0$ 、 $\rho=0$ 、适应度全相同、残差全 0
- 真实数据集成: 端到端跑演化并验证结果

9.5 文档完整性

- 函数级文档: 每个函数有完整 docstring（参数、返回值、示例）
 - 模块级文档: 模块顶部说明职责、设计依据
 - 项目级文档: PROJECT_STATUS.md 记录全部决策和实现历史
-

十、下一步建议

基于当前状态，推荐按以下优先级推进：

短期（1-2 周）

1. 参数线性衰减
2. 实现 $h/\rho/\eta/\mu$ 的线性衰减（文档 11 节）
3. β 暂保持固定（避开方向分歧）
4. 预期 loss 能进一步降低 10-20%
5. 基础可视化
6. loss 曲线图
7. 接受率趋势
8. 帮助直观判断演化行为

中期（1 个月）

1. 整代检查重试
2. 失败时缩小 ρ 重试，提高接受率
3. **patience** 早停
4. 避免无效演化，节省计算
5. β/h 精细调优
6. 按"选择强度+邻域尺度.pdf"的数据驱动方法
7. 3×3 网格实验找最优组合

长期（2-3 个月）

1. **DP** 噪声阶段
2. 接入真实 DP 查询（带噪声）
3. 验证 κ/σ 容忍机制

4. 大规模扩展

5. 共享参考池 $M=512$

6. 支持 50000 条真实数据

附录

A. 关键文档索引

- docs/完整方案.pdf : 完整方案文档
- docs/temp.md : 查询评价器重构文档
- docs/抽样分数+抽样概率.pdf : 抽样机制详细推导
- docs/参数/选择强度+邻域尺度.pdf : β 和 h 设计方法
- PROJECT_STATUS.md : 实现历史和决策记录

B. 项目结构

```
table-diffusion/
├─ src/table_diffusion/      # 核心代码
│   ├─ schema.py             # 属性结构
│   ├─ queries.py            # 查询评价
│   ├─ objective.py          # 残差与loss
│   ├─ fitness.py            # 适应度
│   ├─ distance.py           # 距离计算
│   ├─ sampling.py           # donor抽样
│   ├─ update.py             # 靠近一步
│   ├─ generator.py          # 初始化
│   ├─ evolution.py          # 主循环
│   └─ io.py                 # 结果落盘
├─ tests/                    # 测试 (128 passed)
├─ scripts/run.py            # 入口脚本
├─ configs/                  # 配置文件
│   ├─ schema.yaml
│   └─ measured_50query.json
├─ data/                     # 源数据 (不进git)
├─ outputs/                  # 结果输出 (不进git)
└─ docs/                     # 文档
```


C. Git 提交历史

最近 5 次提交：

1. 779b338 - 实现结果落盘与运行入口脚本
2. e6374a0 - 实现扩散演化主循环并通过测试
3. 3bb4cf9 - 实现合成表初始化并通过测试
4. f44a8b6 - 实现向参考记录靠近一步并通过测试
5. a43a217 - 实现参考记录抽样分数并通过测试

全套测试从 49 → 128 passed , loss 从初始 28932 降至 6102。

项目状态: 核心闭环已完成，可运行并产出结果。下一阶段聚焦参数优化与增强功能。